

Федеральное государственное автономное
образовательное учреждение высшего образования
«Казанский (Приволжский) федеральный университет»



На правах рукописи

Русаков Константин Дмитриевич

**Комплексная методика реидентификации людей
в информационно-поисковых системах**

Специальность 1.2.1 —
«Искусственный интеллект и машинное обучение»

Диссертация на соискание учёной степени
кандидата технических наук

Научный руководитель:
доктор технических наук, доцент
Гончаренко Владимир Иванович

Казань — 2026

Оглавление

	Стр.
Введение	4
 Глава 1. Анализ теоретических основ распознавания и реидентификации человека	 24
1.1 Методы и алгоритмы распознавания человека по лицу	24
1.2 Методы реидентификации человека	27
1.3 Коммерческие системы распознавания человека	30
1.4 Математическая постановка задачи	31
1.5 Выводы по главе	33
 Глава 2. Методика распознавания и реидентификации человека	 35
2.1 Методика детектирования силуэтов и лиц	35
2.1.1 Детектор YOLOv8	35
2.1.2 Функции потерь для детектирования лиц и силуэтов людей	39
2.2 Байесовская модель объединения признаков представлений в задаче реидентификации личности	41
2.2.1 Реидентификация по лицу и телу	42
2.2.2 Интеграция многомодальных биометрических признаков	44
2.2.3 Байесовская модель интеграции	45
2.2.4 Архитектура кодировщиков	49
2.3 Выводы по главе	55
 Глава 3. Оценка эффективности разработанной комплексной методики	 59
3.1 Описание экспериментальной установки и используемых данных	59
3.2 Реализация подхода к детектированию лиц и силуэтов	60
3.2.1 Настройка и подготовка данных	60
3.2.2 Изменение функции потерь	63
3.2.3 Экспериментальные настройки	66
3.2.4 Результаты и их анализ	66
3.2.5 Графическое представление результатов	66

3.3	Байесовский алгоритм классификации в задаче реидентификации личности	69
3.4	Выводы по главе	81
	Заключение	83
	Список сокращений и условных обозначений	87
	Словарь терминов	89
	Список литературы	90
	Список рисунков	99
	Список таблиц	100
	Приложение А. Примеры вставки листингов программного кода	101
	Приложение Б. Очень длинное название второго приложения, в котором продемонстрирована работа с длинными таблицами	106
Б.1	Подраздел приложения	106
Б.2	Ещё один подраздел приложения	108
Б.3	Использование длинных таблиц с окружением <i>longtblr</i> из пакета <i>tabularray</i>	112
Б.4	Форматирование внутри таблиц	115
Б.5	Стандартные префиксы ссылок	117
Б.6	Очередной подраздел приложения	118
Б.7	И ещё один подраздел приложения	118
	Приложение В. Чертёж детали	119

Введение

Актуальность темы исследования.

В условиях стремительного роста объемов визуальных данных, поступающих из распределенных сетей камер наблюдения и иных сенсоров, задача автоматического распознавания и реидентификации людей в видеопотоках становится одним из ключевых направлений развития информационно-поисковых систем (ИПС). Современные ИПС, работающие с видеоданными, должны обеспечивать обнаружение, сопоставление и последующую идентификацию людей в динамичной среде при изменении освещения, ракурса, позы, частоты окклюзий и плотности сцены. От таких систем требуется оперативность (минимум задержек при принятии решений), масштабируемость (устойчивая работа при росте числа сенсоров и пользователей) и надежность (устойчивость к шумам, пропускам и ошибкам промежуточных этапов). Речь идет не только о распознавании как таковом, но и о поиске в визуальном пространстве: по запросу (образцу) необходимо быстро и корректно выделить все релевантные вхождения одного и того же субъекта среди большого массива гетерогенных видеоданных.

Реидентификация человека в ИПС объединяет в одной постановке высокодискриминативную, но часто недоступную модальность лица и устойчиво наблюдаемую, но менее различительную модальность силуэта. Требуется работы в режиме, близком к реальному времени, и допускает строгую количественную оценку на больших открытых наборах данных (CUNK03, Market-1501, MARS).

Традиционные конвейеры обработки в ИПС реидентификации строятся как последовательность этапов: детектирование человека в потоке изображений, отслеживание движений в сцене (трекинг), построение признаковых представлений (эмбеддингов) и, наконец, идентификация по извлеченным признакам. Такая архитектура естественна и технологически проверена, однако она несет типичные риски «каскадного эффекта»: неточность детектирования приводит к деградации качества эмбеддингов, а далее — к ошибкам сопоставления и поиска. В реальных условиях это проявляется особенно заметно: отсутствие фронтального лица, частичная видимость силуэта, пересечения траекторий, вариативность внешнего вида, изменение числа людей в кадре и плотности сцены приводят к росту ложных срабатываний и пропусков. Тем самым задача повышения качества реидентификации в ИПС сводится к согласованной оптимизации всего контура обработки —

от первичного выделения связанных объектов «силуэт-лицо» до стратегии вероятностной интеграции их признаковых описаний при принятии решения.

В современном информационном обществе задачи, связанные с поиском, распознаванием и реидентификацией людей, приобретают все большее значение в связи с активным ростом объемов визуальных данных, получаемых с цифровых видеокамер и иных сенсоров, используемых в системах видеонаблюдения. ИПС реидентификации играют важную роль как в области обеспечения общественной безопасности, так и в интеллектуальных городских системах мониторинга и управления доступом, в транспортной инфраструктуре, на режимных объектах и в системах контроля доступа.

Под *детектированием* в настоящей работе понимается процесс автоматического выделения областей изображения или видеопотока, соответствующих объектам заданного класса (применительно к задаче реидентификации — человеческим лицам и силуэтам). Данный этап критически важен: именно качество выделения связанных объектов «силуэт-лицо» во многом определяет общую точность последующих этапов анализа и реидентификации. В контексте задач идентификации и реидентификации человека детектирование является первым и ключевым этапом обработки данных: именно от его качества зависит корректность работы всех последующих шагов, включая построение эмбедингов и процедуру сопоставления. Ошибки на стадии детектирования приводят к каскадному накоплению неточностей и снижению итоговой точности системы. Для ИПС, работающих в условиях большого потока данных и разнообразия внешних факторов (освещение, ракурс, плотность сцены, частичные перекрытия объектов), детектирование особенно важно: именно оно задает верхнюю границу эффективности алгоритмов реидентификации.

Существенный пласт исследований в области компьютерного зрения посвящён обнаружению и распознаванию лиц. Методы обнаружения лиц [1—6] и методы распознавания лиц [6—10] активно развиваются в течение более чем двух десятилетий. В современных системах изображения лиц по-прежнему остаются предпочтительным источником биометрической информации для идентификации личности. Вместе с тем изображения лиц доступны не всегда, что делает автономное распознавание по лицу неприменимым в ряде эксплуатационных сценариев. Это особенно заметно в уличных и транспортных сценах, при неблагоприятном ракурсе, неполной видимости, окклюзиях или недостаточном разрешении лица.

Наряду с лицевой биометрией развивается распознавание человека по нелицевым признакам. Распознавание человека может быть направлено на идентификацию личности по изображению или видео без обязательного присутствия лица. Существует ряд подходов, основанных на анализе отличных от лица признаков человека. Как показано в работах [11; 12], периодичность походки позволяет обнаруживать идущего человека в последовательности изображений. Походка также использовалась для распознавания людей в видеопоследовательностях. Однако, как отмечалось в [13], подобные подходы часто тестировались на ограниченном числе людей, и их переносимость на большие совокупности субъектов остаётся неоднозначной.

На фоне ограничений автономного распознавания по лицу или по силуэтным признакам всё большую роль играют методы *реидентификации человека* (ReID). Реидентификация человека представляет собой процесс определения и подтверждения личности индивида на основе сравнения его характеристик, полученных из различных источников данных или в разные моменты времени. В контексте компьютерного зрения и обработки изображений речь идёт об идентификации одного и того же человека на разных изображениях или видеозаписях при изменении условий съёмки (освещение, ракурс, поза, фон, одежда и др.). Последние работы по person search и person re-identification условно делятся на одноэтапные методы [14—16] и двухэтапные методы [17—19]. Типичный двухэтапный метод сначала обнаруживает людей, а затем применяет модель распознавания к обнаруженным изображениям. Напротив, одноэтапные методы оптимизируют задачи обнаружения и распознавания людей одновременно. Чтобы повысить различительную способность моделей, в некоторых работах вводятся вспомогательные задачи [17; 20] (например, оценка позы, распознавание атрибутов, семантическая сегментация). В [21] извлекаются признаки видимых частей тела и выполняется сопоставление частичных признаков. В [17] исследуется влияние справочной информации и структур сцены на поиск человека. В рамках отечественных исследований проблема реидентификации человека активно разрабатывается рядом научных школ, включая работы Зайцева А. Ю., Сахарова В. Н., Лапшина С. А. и других, в которых рассматриваются как алгоритмические, так и архитектурные аспекты построения систем идентификации в сложных условиях наблюдения [22—26].

С практической точки зрения ИПС должны не только находить человека «здесь и сейчас», но и сопоставлять наблюдения во времени и пространстве, обес-

печивая корректное «сведение» следов субъекта под изменяющимися условиями. Отсюда вытекают прикладные требования к таким системам:

- инвариантность к внешним факторам (освещение, ракурс, поза, частичная окклюзия, изменчивость одежды и плотности сцены);
- контролируемая вычислительная сложность для работы в режиме, близком к реальному времени;
- формализуемые метрики качества (mAP, CMC/Rank, ROC/PR) с привязкой к эксплуатационным сценариям (порог решения, режим Top-k, режим воздержания при низкой уверенности);
- технологическая интегрируемость в уже развёрнутые платформы наблюдения и аналитики без разрушения существующих регламентов хранения и обработки данных.

Отдельного внимания заслуживает текущая практика внедрения биометрических систем и коммерческих решений. Рост рынка биометрических технологий и широкое распространение систем распознавания лица в России и мире [27—29] показывают высокую востребованность соответствующих методов. Вместе с тем использование коммерческих решений нередко осложняется высокой стоимостью, закрытостью алгоритмов, непрозрачностью метрик качества и отсутствием возможности тонкой адаптации под конкретные сцены и условия эксплуатации. Таким образом, сохраняется запрос на научно обоснованные и воспроизводимые методы, которые могли бы быть интегрированы в реальные ИПС и поддерживали бы контролируемую точность, устойчивость и интерпретируемость принятия решений.

Несмотря на большое количество подходов, существующие ИПС распознавания и реидентификации человека обладают рядом ограничений. Во-первых, большинство существующих решений базируется на использовании одного типа признаков (лицевых либо нелицевых), что не отражает многофакторную природу задачи идентификации в реальных сценах. Такая однофакторность приводит к снижению точности, особенно при отсутствии или частичной видимости ключевой модальности. Во-вторых, многие подходы не обеспечивают эффективной работы в условиях динамично изменяющихся сцен, где количество людей и условия видимости варьируются во времени. В-третьих, существенной проблемой остается неустойчивость алгоритмов в условиях информационной неопределенности: изменения освещения, вариативность поз и ракурсов, динамика движений, окклюзии, взаимодействия людей в сцене.

Перечисленные ограничения мотивируют разработку *комплексной методики реидентификации людей*, учитывающей многофакторность процесса и способной адаптироваться к изменяющимся условиям наблюдения. В настоящей работе развивается подход, в котором ключевую роль играет согласованное использование двух модальностей — лицевой и силуэтной. Подход опирается не на механическое усреднение представлений, а на формализованное вероятностное объединение источников признаков с учетом их текущей доступности и надежности.

В рассматриваемых эксплуатационных сценариях доступный набор модальностей изменяется во времени:

$$\mathcal{M}(t) \subseteq \{f, s\}, \quad (1)$$

где f — лицевая, s — силуэтная модальность; в отдельные моменты времени лицевая модальность может отсутствовать вследствие окклюзий, поворота головы или недостаточного разрешения. Следовательно, методика реидентификации должна не только объединять обе группы признаков, но и адаптивно учитывать их текущую доступность и надежность, перераспределяя вклад модальностей в итоговое решение в зависимости от условий наблюдения.

Актуальность разработки именно многофакторной и адаптивной методики обусловлена тем, что ни один из факторов по отдельности не обеспечивает требуемого уровня точности в реальных условиях эксплуатации. При фиксированном использовании только лицевых признаков качество резко деградирует при частичном или полном отсутствии лица, тогда как использование только силуэта недостаточно для разграничения большой совокупности людей с близким внешним видом. Поэтому совместный учет комплементарных факторов одновременно компенсирует отсутствие или низкое качество отдельной модальности и обеспечивает формирование более информативного признакового представления, непосредственно приводящего к снижению вероятности ошибки реидентификации.

Тем самым актуальность настоящего исследования определяется необходимостью повышения эффективности процессов автоматической реидентификации людей в информационно-поисковых системах в условиях информационной неопределенности и изменяющихся факторов наблюдения при рациональных вычислительных затратах.

Формальная постановка задачи реидентификации.

Пусть на вход ИПС поступает наблюдение человека, представленное двумя связанными модальностями — лицом f и силуэтом s . Обозначим множество классов идентификации (известных личностей в галерее ИПС) как Y ; требуется по доступным наблюдениям модальностей восстановить класс $y \in Y$. Каждой модальности $k \in \{f, s\}$ ставится в соответствие кодировщик

$$\Phi_k: k \mapsto \mathbf{z}_k \in \mathbb{R}^{d_k}, \quad (2)$$

формирующий дискриминативное векторное представление (эмбеддинг) $\mathbf{z}_k$ в пространстве размерности d_k . В практических сценариях не все $\mathbf{z}_k$ доступны одновременно; множество наблюдаемых в момент t модальностей

$$\mathcal{M}(t) \subseteq \{1, \dots, K\} \quad (3)$$

является случайной величиной, определяемой условиями съемки.

Задача распознавания структуры формулируется как многоклассовая вероятностная классификация: по доступным эмбеддингам $\{\mathbf{z}_k: k \in \mathcal{M}(t)\}$ требуется найти оценку идентичности

$$y^* = \arg \max_{y \in Y} P(y \mid \{\mathbf{z}_k: k \in \mathcal{M}(t)\}). \quad (4)$$

При допущении условной независимости компонентов структуры относительно y апостериорная вероятность факторизуется по правилу Байеса

$$P(y \mid \{\mathbf{z}_k\}) \propto P(y) \prod_{k \in \mathcal{M}(t)} P(\mathbf{z}_k \mid y), \quad (5)$$

и при равноправных идентичностях ($P(y) = \text{const}$) решающее правило сводится к многоклассовому MAP-критерию

$$y^* = \arg \max_{y \in Y} \sum_{k \in \mathcal{M}(t)} \log P(\mathbf{z}_k \mid y). \quad (6)$$

Тем самым построение кодировщиков Φ_k (формирование эмбеддингов) и оценка правдоподобий $P(\mathbf{z}_k \mid y)$ являются двумя основными нетривиальными подзадачами, решение которых определяет корректность правила (5) в условиях информационной неопределенности. В настоящей работе Y — множество классов идентификации в галерее ИПС, k принимает значения f (лицо) или s (силуэт).

Степень разработанности темы.

Задачи распознавания человека по изображению и видео, включая детектирование, идентификацию и реидентификацию (ReID), относятся к числу наиболее активно развивающихся направлений цифровой обработки аудиовизуальной информации и распознавания образов. Для распознавания лица исторически сформировались фундаментальные подходы выделения признаков и снижения размерности, включая PCA/«eigenfaces» и LDA, а также различные схемы каскадного детектирования, локализации лицевых ключевых точек и последующего сопоставления признаков. В более поздних работах широкое распространение получили глубокие нейронные сети, обеспечившие качественный переход от ручных признаков к обучаемым эмбедингам [1—10]. Существенный прогресс в развитии дискриминативных эмбедингов связан с метрическим обучением и функциями потерь, формирующими выраженные межклассовые границы в признаковом пространстве, в том числе ArcFace.

Распознавание человека по нелицевым признакам также имеет долгую историю. Помимо походки [11—13], используются силуэт, атрибуты внешнего вида, семантическая сегментация частей тела, контекст и структура сцены. Эти направления важны, поскольку лицо не всегда доступно, а для массовых сцен, нефронтальных ракурсов и больших расстояний до камеры нелицевые признаки становятся основным источником информации о личности.

Современное направление person re-identification сформировалось как ответ на практические задачи мультикамерного наблюдения и поиска людей. Обзоры и систематизации области [30—36] показывают, что сегодня ReID включает широкий спектр постановок и подходов: двухэтапные и одноэтапные схемы, методы person search, part-based and attention-based модели, многомодальные подходы, методы partial matching, re-ranking, графовые и структурные модели. При этом в реальных ИПС качество итогового результата по-прежнему чувствительно к ошибкам ранних стадий обработки и к вариативности условий наблюдения.

В работах [14—16] рассматриваются одноэтапные методы поиска человека, одновременно решающие задачи обнаружения и распознавания. В [17—19] представлены двухэтапные схемы, в которых сначала выполняется локализация человека, а затем — извлечение признаков и сопоставление. В ряде работ используются вспомогательные задачи [17; 20], например оценка позы и распознавание атрибутов, а также механизмы выделения видимых частей тела [21]. Всё это подтверждает, что область ReID движется в сторону более сложных и информативных многомодальных моделей.

В отечественной научной повестке задача реидентификации и построения систем идентификации в сложных условиях наблюдения разрабатывается рядом научных школ и исследовательских коллективов. В работах [22—26] рассматриваются как алгоритмические, так и архитектурные аспекты построения систем идентификации человека по видеоизображениям, а также комбинированные решения, учитывающие лицевые, силуэтные и иные биометрические признаки. Эти исследования подтверждают актуальность темы и наличие устойчивого научного интереса к проблеме.

Отдельную ветвь составляют многомодальные подходы к распознаванию и идентификации, в которых объединяются комплементарные источники информации: лицо, силуэт, походка, атрибуты, контекст наблюдения и др. [37—41]. Предлагаются как схемы объединения на уровне признаков (конкатенация, линейное объединение), так и более сложные механизмы на уровне оценок и решающих правил. Вероятностные и байесовские постановки [42—47] позволяют интерпретировать процесс принятия решения как объединение нескольких источников свидетельств с учётом неопределённости, что особенно важно для ИПС, работающих в изменчивых сценах и при неполной доступности модальностей.

Состояние области показывает, что основные научные и инженерные трудности связаны с тремя узкими местами. Во-первых, качество результата существенно зависит от первичного детектирования объектов, особенно если в контуре ReID используются как силуэт, так и лицо. Во-вторых, требуется формировать устойчивые и одновременно дискриминативные эмбединги для каждой модальности, сохраняя сопоставимость представлений в пределах одной системы принятия решения. В-третьих, необходима такая интеграция модальностей, которая была бы обоснованной, интерпретируемой и корректно работала бы в условиях пропуска или деградации одной из модальностей.

Следовательно, несмотря на значительное число работ, сохраняется потребность в методически целостном решении, ориентированном именно на информационно-поисковые системы, где результат определяется не только точностью отдельного алгоритма, но и согласованностью процессов детектирования, формирования эмбедингов и интеграции признаков в рамках общего контура принятия решения.

Структура комплексной методики реидентификации.

Разработанная в настоящей работе методика реализует единый конвейер обработки видеокadra в ИПС и состоит из трех функциональных уровней, последовательно реализующих кодировщики Φ_k и оценку правдоподобий $P(\mathbf{z}_k | y)$.

Уровень 1 — согласованная локализация связанных объектов «силуэт-лицо». На вход поступает изображение или кадр видеопотока, на выходе — локализованные пары силуэт-лицо с указанием взаимной вложенности рамок. Ключевая особенность — согласованная локализация: обнаружение лица внутри ограничивающей рамки силуэта с дополнительным штрафом за ошибку локализации лица. Формально это достигается модификацией функции потерь детектора:

$$\mathcal{L} = \mathcal{L}_0 + \lambda_{\text{face}} \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{\text{face}}(i) \mathcal{L}_{\text{face}}(i), \quad (7)$$

где $\mathcal{L}_0$ — стандартный функционал детектора YOLOv8, $\mathbb{I}_{\text{face}}(i)$ — индикатор того, что i -я ячейка содержит лицо, $\mathcal{L}_{\text{face}}(i)$ — добавочный штраф за ошибку его локализации, λ_{face} — управляющий коэффициент.

Уровень 2 — формирование дискриминативных эмбеддингов лица и силуэта. Для каждой модальности $k \in \{f, s\}$ строится модально-специфический кодировщик Φ_k на базе архитектуры Vision Transformer (ViT), обучаемый по функции потерь метрического обучения ArcFace

$$\mathcal{L}_{\text{ArcFace}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s \cos(\theta_{y_i} + m))}{\exp(s \cos(\theta_{y_i} + m)) + \sum_{j \neq y_i} \exp(s \cos \theta_j)}, \quad (8)$$

с последующей L_2 -нормировкой полученных представлений. Применение ArcFace формирует выраженные межклассовые границы $\theta_{y_i} + m$ в пространстве направлений эмбеддингов, что и обеспечивает дискриминативность Φ_k для каждой модальности изолированно.

Уровень 3 — вероятностная интеграция и принятие решения. Для каждого класса $y \in Y$ распределение эмбеддингов $\mathbf{z}_k$ аппроксимируется многомерной гауссовой моделью

$$P(\mathbf{z}_k | y) = \frac{1}{(2\pi)^{d_k/2} |\Sigma_{y,k}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{z}_k - \boldsymbol{\mu}_{y,k})^\top \Sigma_{y,k}^{-1}(\mathbf{z}_k - \boldsymbol{\mu}_{y,k})\right), \quad (9)$$

где $\boldsymbol{\mu}_{y,k}$ и $\Sigma_{y,k}$ — центроид и ковариационная матрица класса y в признаковом пространстве модальности k , оцениваемые по обучающей выборке. Подстановка в МАР-критерий дает решающее правило, в котором логарифм правдоподобия включает расстояние Махаланобиса с обратной ковариацией $\Sigma_{y,k}^{-1}$. Тем самым

модальность с меньшей внутриклассовой дисперсией (более компактными кластерами личностей) автоматически дает более «острое» правдоподобие и доминирует в $\arg\max$; адаптивный вклад каждой модальности достигается без ручной подстройки весов и без введения дополнительного гиперпараметра комбинирования — роль коэффициентов доверия играют именно матрицы $\Sigma_{y,k}$.

Перечисленные три уровня образуют единый вычислительный контур
 детектирование $\longrightarrow$ эмбединги (ViT + ArcFace) $\longrightarrow$ байесовская интеграция (MAP)
 обеспечивающий поэтапное повышение качества реидентификации и минимизацию каскадного эффекта накопления ошибок.

Научно-техническая задача, решаемая в работе.

Научно-техническая задача, решаемая в диссертации, состоит в повышении эффективности информационных процессов автоматического распознавания и реидентификации людей в информационно-поисковых системах, функционирующих в условиях информационной неопределенности и изменяющихся условий наблюдения, за счет согласованного улучшения локализации связанных объектов «силуэт-лицо», формирования устойчивых дискриминативных признаков представлений лица и силуэта и их вероятностной интеграции при принятии решения.

Цель исследования.

Целью исследования является повышение эффективности информационных процессов распознавания и реидентификации людей в информационно-поисковых системах путем разработки комплексной методики, основанной на согласованном детектировании связанных объектов «силуэт-лицо», раздельном извлечении дискриминативных эмбедингов лица и силуэта на базе ViT и ArcFace и их вероятностной интеграции на основе байесовской модели и MAP-критерия; методика обеспечивает повышение точности реидентификации в режиме, близком к реальному времени, при рациональных вычислительных затратах.

Объект исследования.

Объектом исследования являются информационные процессы автоматического распознавания и реидентификации людей в информационно-поисковых системах, функционирующих в условиях неполноты данных и динамически изменяющейся среды наблюдения, в режиме, близком к реальному времени.

Предмет исследования.

Предметом исследования являются методы, модели и программно-алгоритмические средства согласованного детектирования связанных объектов «силуэт-лицо», формирования дискриминативных лицевых и силуэтных эмбедингов и их вероятностной интеграции для повышения качества реидентификации людей в условиях неполноты данных и изменяющихся условий наблюдения.

Задачи исследования.

Для достижения поставленной цели решены следующие задачи:

1. проведен анализ существующих подходов к распознаванию и реидентификации людей в условиях информационной неопределенности (детектирование, формирование признаков представлений, интеграция модальностей) и дана оценка их применимости для информационно-поисковых систем, работающих в условиях динамической сцены и неполноты данных;
2. разработан метод формирования дискриминативных признаков представлений (эмбедингов) для лица и силуэта на основе кодировщиков Vision Transformer (ViT) и метрического обучения (ArcFace), обеспечивающий устойчивость представлений к изменениям условий наблюдения;
3. разработан метод вероятностной интеграции лицевых и силуэтных эмбедингов на основе байесовской модели и многоклассового MAP-критерия, обеспечивающий устойчивое принятие решения при неполноте данных и автоматическое взвешивание модальностей через ковариационные матрицы класса в гауссовых правдоподобиях, без введения дополнительного гиперпараметра комбинирования;
4. разработана модификация критерия обучения нейросетевого детектора (на базе архитектуры YOLOv8) для согласованной локализации связанных объектов «силуэт-лицо», включающая дополнительный компонент функции потерь $\mathcal{L}_{\text{face}}$ и коэффициент λ_{face} ; проведено исследование влияния λ_{face} на показатели качества обнаружения лица при сохранении стабильности детекции класса «силуэт»;
5. реализована программная модель и проведены вычислительные эксперименты на репрезентативных наборах данных (CUHK03, Market-1501, MARS) для задачи реидентификации людей; выполнено сравнение с современными подходами и дана оценка эффективности предложенной методики.

Методология и методы исследования.

При проведении исследования использованы методы и средства компьютерного зрения и машинного обучения, включая глубокие нейросетевые архитектуры для детектирования объектов на изображениях и в видеопотоках, методы обучения представлений (эмбеддингов) с применением специализированных функций потерь метрического обучения (ArcFace), а также методы вероятностного моделирования и принятия решений (байесовский подход и MAP-критерий) для интеграции модальностей. Для верификации и сравнения использованы общепринятые метрики качества (Precision/Recall, mAP, ROC/PR-кривые, Rank-k и др.) и вычислительные эксперименты на открытых наборах данных, а также сравнение с современными state-of-the-art подходами.

Научная новизна работы.

Научная новизна диссертационной работы заключается в разработке комплекса методов автоматического распознавания и реидентификации людей в информационно-поисковых системах в условиях информационной неопределенности, а именно:

1. разработан метод обучения нейросетевого детектора для согласованного выделения связанных объектов «силуэт-лицо», отличающийся модификацией функции потерь за счет введения дополнительного компонента $\mathcal{L}_{\text{face}}$ и адаптивного коэффициента λ_{face} , штрафующих модель за ошибки локализации лица в границах силуэта и повышающих полноту извлечения признаков без деградации базового детектирования силуэта;
2. предложен метод формирования дискриминативных векторных представлений (эмбеддингов) для лицевой и силуэтной модальностей, отличающийся от существующих решений двухканальной схемой на базе кодировщиков Vision Transformer (ViT) и функцией потерь метрического обучения ArcFace с последующей L_2 -нормировкой; такая схема обеспечивает извлечение контекстных зависимостей и формирование устойчивых межклассовых границ для каждой модальности изолированно с подготовкой эмбеддингов к вероятностной интеграции;
3. разработан метод интеграции эмбеддингов лица и силуэта и принятия решения на основе байесовской модели и многоклассового MAP-критерия (максимума апостериорной вероятности), отличающийся автоматическим взвешиванием модальностей через ковариационные матрицы класса Σ_y в гауссовых правдоподобиях; такое взвешивание обеспечи-

вает адаптивный вклад каждой модальности без ручной подстройки весов и без введения дополнительного гиперпараметра комбинирования, а также корректное поведение решающего правила при временном отсутствии или зашумлении одной из модальностей.

Теоретическая значимость работы.

Теоретическая значимость работы заключается в развитии формального подхода к описанию и оценке информационных процессов автоматической реидентификации людей в условиях информационной неопределенности за счет построения вероятностной модели интеграции лицевых и силуэтных эмбеддингов и обоснования решающего правила на основе многоклассового MAP-критерия с автоматическим взвешиванием модальностей через ковариационные матрицы Σ_y гауссовых правдоподобий.

Практическая значимость работы.

Практическая значимость работы состоит в возможности применения разработанного методического и программного обеспечения в составе информационно-поисковых систем распознавания и реидентификации людей в изменяющихся условиях наблюдения (освещение, ракурс, окклюзии, изменение числа людей в кадре), в частности в системах визуального мониторинга и безопасности, где требуется устойчивость к отсутствию или снижению качества отдельных модальностей и рациональное использование вычислительных ресурсов. Применение разработанного методического и программного обеспечения подтверждено внедрением в деятельности ФГБУ «НИЦ «Институт имени Н. Е. Жуковского»» с подтвержденным сокращением времени принятия решения до 5 % при эксплуатации систем визуального наблюдения. Разработанные программные средства защищены свидетельствами о государственной регистрации программ для ЭВМ [48; 49].

Положения, выносимые на защиту.

На защиту выносятся следующие основные положения:

1. метод обучения нейросетевого детектора (на базе архитектуры YOLOv8) для локализации связанных объектов «силуэт-лицо», использующий модифицированную функцию потерь с компонентом $\mathcal{L}_{\text{face}}$ и коэффициентом λ_{face} ; экспериментально установлено, что значения λ_{face} в диапазоне 2,0–2,7 обеспечивают максимальные показатели точности обнаружения лиц без статистически значимой деградации качества детектирования класса «силуэт»;

2. метод извлечения устойчивых лицевых и силуэтных эмбеддингов с использованием кодировщиков Vision Transformer и функции потерь ArcFace, обеспечивающий получение высокоинформативных представлений и минимизацию пересечений классов в признаковом пространстве при вариативности условий наблюдения;
3. байесовская модель интеграции лицевых и силуэтных эмбеддингов и алгоритм принятия решения по многоклассовому MAP-критерию с автоматическим взвешиванием модальностей через ковариационные матрицы класса Σ_y в гауссовых правдоподобиях, обеспечивающие устойчивую реидентификацию при неполноте данных без введения дополнительного гиперпараметра комбинирования; по результатам вычислительных экспериментов в задаче реидентификации личности (в постановке многоклассовой закрытой идентификации, Top-1) метод показал высокую эффективность: получены макро-усредненные показатели на наборе CUNK03 - Precision 95,65 %, Recall 95,54 %, F_1 -мера 94,31 %, Accuracy 93,42 %; по метрике mAP достигнуты значения 95,65 % / 98,3 % / 89,2 % для наборов CUNK03 / Market-1501 / MARS соответственно, что превосходит базовые способы линейного объединения признаков.

Соответствие паспорту научной специальности.

Диссертационная работа соответствует специальности 1.2.1 «Искусственный интеллект и машинное обучение» и направлениям исследований паспорта специальности:

- п. 4 (методы для обработки текстов, изображений, речи, биомедицинских данных) — в части разработки методов обработки изображений и видеоданных: согласованного детектирования связанных объектов «силуэт-лицо», формирования ROI и извлечения дискриминативных эмбеддингов лица и силуэта;
- п. 5 (методы поиска знаний и закономерностей, интеграция машинного обучения с классическим моделированием) — в части интеграции нейросетевых эмбеддингов (ViT + ArcFace) с классической байесовской моделью многомодального вывода и MAP-решающим правилом с автоматическим взвешиванием модальностей через ковариационные матрицы класса;

- п. 17 (исследования в области многослойных алгоритмических конструкций, в том числе многослойных нейросетей) — в части разработанных нейросетевых архитектур: модифицированного детектора YOLOv8 (с введением компонента $\mathcal{L}_{\text{face}}$ и коэффициента λ_{face} в функцию потерь) и двухканальной схемы ViT-кодировщиков для лица и силуэта, обучаемой по ArcFace.

Достоверность и обоснованность результатов исследования.

Достоверность полученных научных результатов подтверждается согласованностью теоретических выводов с результатами вычислительных экспериментов, корректным выбором и применением общепринятых метрик качества, воспроизводимостью экспериментальной процедуры и сравнением с современными решениями на стандартных наборах данных (CUHK03, Market-1501, MARS). Обоснованность результатов обеспечивается непротиворечивостью исходных допущений, использованием апробированных методов компьютерного зрения, распознавания образов и вероятностного моделирования, а также достаточной полнотой анализа публикаций по исследуемой проблеме.

Апробация результатов работы.

Основные положения и результаты диссертационной работы докладывались и обсуждались на плановых научно-технических конференциях ИПУ РАН (г. Москва, 2020–2022 гг.), а также на международных и всероссийских конференциях по информатике, интеллектуальным системам, управлению и компьютерному зрению, в том числе серий MLSД (Management of Large-Scale System Development, IEEE), ICCT, УБС («Управление большими системами»), МКПУ (Мультиконференция по проблемам управления), ВСПУ (Всероссийское совещание по проблемам управления), DSPA («Цифровая обработка сигналов и ее применение») и других.

Внедрение результатов работы.

Результаты диссертационной работы «Методика распознавания и реидентификации людей в информационно-поисковых системах» использованы в деятельности ФГБУ «НИЦ «Институт имени Н. Е. Жуковского»» в работах по автоматическому распознаванию и реидентификации объектов. Применение результатов подтверждено актом о внедрении (утвержден 10.06.2024). В акте отмечено, что разработанное методическое и программное обеспечение позволяет эффективно детектировать объекты и преобразовывать их в численные характеристики (эмбединги), улучшая точность идентификации и обеспечивая

повышение эффективности и сокращение времени принятия решения до 5 % при использовании систем визуального наблюдения и безопасности. Программные средства, реализующие ключевые компоненты предложенной методики, защищены свидетельствами о государственной регистрации программ для ЭВМ [48; 49].

Личный вклад автора.

Основные научные результаты получены лично автором. Постановка задачи исследования осуществлялась совместно с научным руководителем. Автором выполнены разработка ключевых алгоритмических решений, реализация программных модулей, постановка и проведение вычислительных экспериментов, анализ и интерпретация результатов.

Публикации.

Результаты диссертационной работы отражены в 13 научных публикациях автора, в том числе в 4 публикациях в изданиях из перечня ВАК при Минобрнауки РФ, 4 статьях из перечня научных изданий, индексируемых в международных наукометрических базах данных Web of Science и/или Scopus, а также в 5 рецензируемых изданиях; получены 2 свидетельства о государственной регистрации программ для ЭВМ.

Непосредственно по теме диссертации (распознавание и реидентификация людей в информационно-поисковых системах на основе байесовского объединения лицевой и силуэтной модальностей) результаты изложены в трех самостоятельных публикациях автора [50—52]:

- *Русаков К.Д.* Байесовская модель объединения признаков представлений в задаче реидентификации личности // Управление большими системами. 2025. Вып. 115. С. 183–202;
- *Русаков К.Д.* Байесовский алгоритм классификации в задаче реидентификации личности // Известия Юго-Западного государственного университета. 2025. Т. 29, № 3. С. 92–108;
- *Rusakov K.D.* Improved Detection of Related Objects on the Example of Human Re-Identification Task // Proceedings of the 17th International Conference Management of Large-Scale System Development (MLSD). Moscow: IEEE, 2024.

Универсальность предложенного методического аппарата (независимое извлечение признаков описаний составных частей объекта и их последующая интеграция) подтверждена применением автора в смежных предметных областях. Соответствующие результаты опубликованы в следующих работах:

В изданиях, входящих в перечень ВАК при Минобрнауки РФ [53; 54]:

- Русаков К. Д., Генов А. А., Хиль С. Ш. Методика решения задачи антиспуфинга по ограниченному количеству фотографий // Программные продукты и системы. 2020. Т. 33, № 1. С. 54–60;
- Русаков К. Д., Чехов А. В. Двухэтапный подход к распознаванию коррозии металлических конструкций с использованием сверточных нейронных сетей в ходе проведения инспекций промышленных объектов // Известия Юго-Западного государственного университета. 2021. Т. 25, № 3. С. 152–166.

В изданиях, индексируемых в Scopus и Web of Science [55–57]:

- Rusakov K. D. Automatic Modular License Plate Recognition System Using Fast Convolutional Neural Networks // Proceedings of the 13th International Conference Management of Large-Scale System Development (MLSD). Moscow: IEEE, 2020. P. 1–4;
- Rusakov K. D., Seliverstov D. E., Osipov V. V., Reshetnikov V. N. Definition of Unique Objects by Convolutional Neural Networks Using Transfer Learning // International Journal of Advanced Computer Science and Applications. 2020. Vol. 11, Iss. 11. P. 48–54;
- Rusakov K. D. Using Convolutional Neural Networks for Estimating the Speed and Acceleration of UAVs During Takeoff and Landing Through Multicamera Detection // Proceedings of the 16th International Conference Management of Large-Scale System Development (MLSD). Moscow: IEEE, 2023.

В других рецензируемых изданиях [58–62]:

- Русаков К. Д. Использование глубокого обучения и беспилотных летательных аппаратов для мониторинга мусора в прибрежных зонах // Труды 14-го Всероссийского совещания по проблемам управления (ВСПУ-2024). М.: ИПУ РАН, 2024. С. 1157–1162;
- Русаков К. Д. Подход к распознаванию утопающих с помощью глубокого обучения // Труды 16-й Всероссийской мультikonференции по проблемам управления (МКПУ-2023, Волгоград). Волгоград: ВГТУ, 2023. № 1. С. 257–259;
- Исхакова А. О., Русаков К. Д., Исхаков А. Ю., Мамченко М. В. Детектирование деструктивного мультимедиа-контента в социо-киберфизической системе мониторинга сети Интернет // Труды 17-й Всероссийской шко-

лы-конференции молодых ученых «Управление большими системами» (УБС-2021). Москва - Звенигород: ИПУ РАН, 2021. С. 202–212;

- *Русаков К.Д., Диане С.А., Россоловский И.А.* Алгоритмы обработки информации и управления автономным мультикоптером в задаче мониторинга протяженных объектов // Труды 17-й Всероссийской школы-конференции молодых ученых «Управление большими системами» (УБС-2021). Москва - Звенигород: ИПУ РАН, 2021. С. 490–497;
- *Русаков К.Д., Гончаренко В.И., Горелов А.В.* Модель прогноза технического состояния космического аппарата на основе искусственных модульных нейросетей // Труды 19-й Международной конференции «Цифровая обработка сигналов и ее применение - DSPA-2017». М.: РНТОРЭС имени А.С. Попова, 2017. Т. 2. С. 808–813.

Свидетельства о государственной регистрации программ для ЭВМ [48; 49]:

- *Русаков К.Д.* Программа для реидентификации личности на основе байесовского объединения эмбедингов лица и тела: Свидетельство о государственной регистрации программы для ЭВМ № 2026617996 РФ; Зарег. 23.03.2026;
- *Русаков К.Д., Тевяшов Г.К.* Программа для наблюдения, захвата рабочей сцены и детектирования малоразмерных объектов в их тесном скоплении: Свидетельство о государственной регистрации программы для ЭВМ № 2023686143 РФ; Зарег. 04.12.2023.

Объём и структура работы.

Диссертация состоит из введения, 3 глав, заключения и 3 приложений. Полный объём диссертации составляет 119 страниц, включая 13 рисунков и 7 таблиц. Список литературы содержит 88 наименований.

Краткое содержание работы.

Во введении обоснованы актуальность темы исследования, ее теоретическая и практическая значимость, дана формальная постановка задачи реидентификации людей в ИПС. Определены объект и предмет исследования, сформулированы цель и задачи, приведены элементы научной новизны, сведения об апробации, внедрении и структуре работы.

Первая глава посвящена анализу теоретических основ распознавания и реидентификации людей в составе информационно-поисковых систем. В разделе 1.1 рассматриваются методы и алгоритмы распознавания человека по лицу

как высокоинформативной, но уязвимой модальности: классические подходы (PCA/«eigenfaces», LDA, каскады Виолы-Джонса, HOG и др.) и современные глубинные архитектуры, в частности с функциями потерь метрического обучения (ArcFace) и механизмами устойчивого формирования лицевых представлений в неконтролируемых условиях съемки. В разделе 1.2 анализируются методы реидентификации, выходящие за рамки чисто лицевой биометрии: подходы, основанные на силуэтных, атрибутивных и многомодальных признаках, одно- и двухэтапные схемы поиска, методы переранжирования результатов и частичного сопоставления; систематизированы вероятностные и байесовские постановки. В разделе 1.3 рассматриваются коммерческие системы распознавания человека, отечественные и зарубежные, анализируются их характеристики, области применения и ограничения. В разделе 1.4 формулируется математическая постановка задачи реидентификации в контуре ИПС: вводятся множества и отображения, описывающие процесс распознавания, целевые функции и эксплуатационные ограничения (ограниченность ресурсов, требования к метрикам качества и режиму, близкому к реальному времени). В разделе 1.5 подводятся итоги анализа, обобщаются выявленные недостатки однофакторных решений и фиксируются требования к согласованной локализации связанных объектов «силуэт-лицо», формированию признаков и их интеграции.

Вторая глава посвящена разработке комплексной методики реидентификации людей в составе ИПС. Глава структурирована по логике «согласованная локализация «силуэт-лицо» - формирование дискриминативных эмбеддингов - вероятностная интеграция модальностей», что отражает последовательность ключевых информационных процессов в ИПС и обеспечивает поэтапное повышение качества при минимизации каскадного эффекта накопления ошибок. В разделе 2.1 описывается метод обучения детектора связанных объектов «силуэт-лицо» на базе архитектуры YOLOv8; анализируются особенности сцен массового наблюдения и формулируется модифицированная функция потерь с компонентом $\mathcal{L}_{\text{face}}$ и коэффициентом λ_{face} . В разделе 2.2 разрабатывается метод формирования дискриминативных эмбеддингов лица и силуэта с использованием специализированных кодировщиков Vision Transformer и функции потерь ArcFace; рассматриваются вопросы стандартизации признаков, L_2 -нормировки, выбора размерности и построения устойчивых векторных представлений. В разделе 2.3 формализуется метод вероятностной интеграции лицевых и силуэтных эмбеддингов на основе байесовской модели и многоклассового MAP-критерия;

вводятся гауссовы правдоподобия с параметрами $\mu_{y,k}$ и $\Sigma_{y,k}$, обосновывается автоматическое взвешивание модальностей через расстояние Махаланобиса, рассматривается поведение решающего правила при отсутствии или зашумлении одной из модальностей. В разделе 2.4 подводятся выводы по главе и обобщаются достоинства предложенного контура.

Третья глава посвящена экспериментальной оценке эффективности разработанной комплексной методики реидентификации людей. В разделе 3.1 описаны экспериментальная установка, серверная инфраструктура и используемые наборы данных (CUNK03, Market-1501, MARS). В разделе 3.2 приведены результаты исследования влияния коэффициента λ_{face} на качество согласованной локализации связанных объектов «силуэт-лицо»: метрики Precision, Recall, mAP@0.5 и mAP@0.5:0.95, матрицы ошибок и характерные примеры работы детектора. В разделе 3.3 представлены результаты оценки качества формируемых эмбеддингов и итогового качества вероятностной интеграции модальностей: t -SNE-визуализации признакового пространства, ROC- и PR-кривые, количественные метрики, а также сравнение с современными методами ReID по метрике mAP, подтверждающее превосходство байесовской схемы над линейным объединением признаков. В разделе 3.4 сформулированы выводы по главе.

В *заключении* сформулированы основные результаты и выводы диссертационного исследования, подтверждающие достижение поставленной цели и практическую значимость разработанной комплексной методики реидентификации людей в информационно-поисковых системах.

Глава 1. Анализ теоретических основ распознавания и реидентификации человека

В эпоху, когда цифровые технологии становятся неотъемлемой частью многих сфер жизни общества, важность и актуальность задачи распознавания и реидентификации личности постоянно растет. Этот процесс играет ключевую роль в разнообразных областях, начиная от вопросов безопасности и заканчивая разработкой персонализированных цифровых сервисов. Прогресс в методах распознавания личности не только улучшает точность и эффективность идентификации человека, но также способствует внедрению инноваций и положительным изменениям в социальных, экономических и технологических аспектах современного общества.

1.1 Методы и алгоритмы распознавания человека по лицу

Распознавание лиц является одной из задач в области распознавания визуальных образов. Люди постоянно анализируют визуальные образы, получая информацию через глаза, которую мозг интерпретирует как значимые концепции. Для компьютера, будь то изображение или видео, это представляет собой матрицу из множества пикселей. Задача машины — определить, какой концепт представляет собой определенная часть данных. Это общая проблема классификации в распознавании визуальных моделей. В распознавании лиц нужно установить, кому принадлежит лицо в той части данных, которую машины воспринимают как лицо. Это специализированная задача. В широком смысле распознавание лиц включает в себя связанные технологии для создания системы распознавания лиц. Оно охватывает обнаружение лиц, определение положения лица, распознавание личности, предварительную обработку изображений и т. д. Алгоритм обнаружения лиц заключается в определении координат всех лиц на изображении. Это процесс сканирования всего изображения для определения, является ли кандидатская область лицом. Вывод системы координат лица может быть квадратным, прямоугольным и т. д. Положение лица — это координаты особенностей лица в системе координат обнаружения лица. Современные технологии позициони-

рования в основном реализуются с помощью фреймворков глубокого обучения. По сравнению с обнаружением лиц, время вычислений для алгоритма позиционирования лица значительно короче. Технология распознавания лиц основывается на последовательности шагов, которые преобразуют исходное изображение в конкретные данные, позволяющие идентифицировать или верифицировать человека.

На первом этапе собираются исходные изображения лиц. Эти изображения могут быть получены с камер видеонаблюдения, фотографий или видеопотока. Предобработка включает в себя такие операции, как нормализация размера, коррекция освещенности и контрастности. Это можно выразить как функцию предобработки P :

$$I_{pp} = P(I_{raw}), \quad (1.1)$$

где I_{raw} — исходное изображение, I_{pp} — предобработанное изображение.

После локализации лица на изображении следующим шагом является извлечение характерных признаков лица, в частности контуров глаз, носа, рта и формы лица. Процесс может быть представлен как функция F :

$$f_{face} = F(L), \quad (1.2)$$

где f_{face} — набор признаков лица, извлеченных из локализованного изображения лица L .

Извлеченные признаки сравниваются с данными в базе для идентификации или верификации личности. Этот процесс представим как функцию сопоставления M :

$$R = M(f_{face}, DB), \quad (1.3)$$

где R — результат сопоставления, DB — база данных признаков лиц.

На основе результатов сопоставления принимается решение о том, соответствует ли обнаруженное лицо какой-либо записи в базе данных. Этот шаг выражается как функция верификации (идентификации) V :

$$ID = V(R), \quad (1.4)$$

где ID — идентификатор лица или подтверждение его соответствия записи в базе данных.

Эти шаги составляют основу процесса распознавания лиц. Чтобы более глубоко погрузиться в область технологий распознавания лиц, необходимо тщательно рассмотреть ряд научных работ и исследований, проведенных в этой

области. Важно ознакомиться с различными методами и алгоритмами, использованными для распознавания лиц, начиная от традиционных подходов (HAAR Cascade) и до современных техник глубокого обучения и нейронных сетей. Особое внимание следует уделить исследованиям, касающимся извлечения и анализа признаков лица, методов сопоставления и сравнения признаков, а также улучшения точности и надежности систем распознавания. Кроме того, важно рассмотреть вопросы, связанные с эффективностью работы алгоритмов в различных условиях: изменение освещения, разные ракурсы лица и динамика выражений. Изучение указанных работ дает комплексное представление о текущем состоянии технологии, ее ограничениях и потенциале для будущих улучшений.

В области распознавания лиц два метода, не связанных с глубоким обучением, — это анализ главных компонент (PCA) и линейный дискриминантный анализ (LDA).

Анализ главных компонент (PCA) считается одним из самых популярных методов уменьшения размерности данных. В контексте алгоритмов распознавания лиц PCA используется для извлечения особенностей лица. Этот метод был введен в область распознавания лиц в 1991 году Турком и Пентлендом из Медиа Лаборатории Массачусетского технологического института (MIT) [20]. Основная цель PCA — устранить избыточную информацию и шум из данных, сохраняя при этом их ключевые характеристики, существенно сокращая размерность данных, ускоряя их обработку и экономя время и ресурсы. Классическим примером алгоритма на основе PCA является алгоритм «eigenface» [63; 64].

Линейный дискриминантный анализ (LDA) используется для классификации лиц в наборах данных, где имеются метки классов [65]. В отличие от PCA, который стремится максимизировать дисперсию данных после сокращения размерности, LDA направлен на минимизацию внутриклассовой дисперсии и максимизацию межклассовой дисперсии. Это означает, что LDA является методом с учителем для уменьшения размерности, использующим информацию о метках для максимального разделения различных категорий данных.

Оба метода, PCA и LDA, являются важными в классическом распознавании лиц и лежат в основе многих современных методов, основанных на глубоком обучении. Они представляют собой фундаментальные подходы в обработке изображений и распознавании лиц до эры глубокого обучения.

В работе [66] использовался алгоритм HAAR Cascade для распознавания лиц, а также статистические классификаторы данных — анализ главных компо-


нент (PCA) и линейный дискриминантный анализ (LDA) — для создания методов распознавания лиц. В эксперименте были проведены сравнительные тесты и сделан вывод, что оба метода имеют одинаковую точность 98%, что является лучшим результатом для классификации и распознавания лиц.

В работе [67] было предложено использовать компьютерное зрение в системах видеонаблюдения для распознавания лиц в реальном времени. Эксперимент был реализован на оборудовании Raspberry Pi 3 с применением алгоритма Виолы-Джонса и функции гистограммы направленных градиентов (HOG) для извлечения черт лица с помощью глубокого обучения. Результат эксперимента, основанный на глубоком обучении, показал хорошую точность в идентификации лиц и последующем распознавании людей через видеопоток.

1.2 Методы реидентификации человека

В эпоху строительства «умных» городов по всему миру устанавливается большое количество высококачественных камер видеонаблюдения, которые генерируют многочисленные видеоматериалы. Анализ и использование данных о пешеходах становятся практически значимой задачей. Эти данные не только помогают правоохранительным органам быстро находить подсказки о подозреваемых или пропавших детях и пожилых людях, но и позволяют предпринимателям извлекать закономерности поведения пешеходов для более рационального использования коммерческих ресурсов. Реидентификация личности [34] возникает как необходимость времени и является ключевой технологией в создании интеллектуальных систем наблюдения. Эта технология находит применение во многих практических сценариях, в частности в статистике движения людей, обнаружении уличных событий и анализе поведения личности. Реидентификация человека [34] подразумевает использование технологий компьютерного зрения для определения личности конкретного человека в системе мониторинга с использованием множества непересекающихся камер. Ставя интересующий запрос, задача реидентификации человека заключается в поиске других изображений или видеопоследовательностей из коллекции, собранной мультикамерной системой, и определении, кто является этим человеком, как показано на рис. 1.1.

**Схема информационных процессов ИПС реидентификации
и место предложенной методики**



Концепция реидентификации человека впервые была определена в 2006 году в работе [68]. С тех пор данное направление пережило быстрое развитие, и ученые всего мира провели обширные исследования этой задачи, разработав множество подходов. Однако существующие подходы многочисленны и имеют различные акценты. Поэтому, чтобы помочь исследователям, вступающим в эту область, быстро ориентироваться в ее развитии и получить обзор перспективных направлений, в настоящем разделе изучается поле реидентификации человека и подводятся итоги связанных с ним понятий и достижений.

В ряде фундаментальных работ [31; 32; 69] представлен обзор современных тенденций в области реидентификации человека и анализ крупных наборов данных, а также методов глубокого обучения. Однако данные исследования фокусируются преимущественно на отдельных аспектах: авторы [70; 71] детально рассматривают различные фреймворки и подходы к оценке эффективности, а также затрагивают задачу реидентификации гетерогенных личностей, но в их обзорах отсутствует углубленная классификация алгоритмов и не уделяется должного внимания широкому спектру методов (в частности, переранжированию результатов). В более ранних работах, в частности [30], реидентификация изучалась до формирования доминирующей роли глубокого обучения, которое начало активно развиваться после 2014 года. Это привело к тому, что в обзоре [30] часть современных методов и достижений, связанных с применением сверточных нейронных сетей и трансформеров, по понятным причинам не представлена. В относительно недавнем исследовании [31] авторы провели детальный анализ датасетов, функций потерь и методов реидентификации человека, однако не представили логическую классификацию существующих подходов и не рассмотрели целый ряд важных аспектов, в частности процедуры переранжирования (re-ranking) результатов и стратегий на основе сетей камер, которые имеют большое практическое значение в реальных системах видеонаблюдения. Таким образом, несмотря на очевидный прогресс в области реидентификации, остается потребность в более целостном и структурированном обзоре, который охватил бы не только современные алгоритмы глубокого обучения, но и их интеграцию в многоаспектные системы обработки.

1.3 Коммерческие системы распознавания человека

Российский рынок биометрических технологий за период с 2014 по 2018 год показал значительный рост. Ежегодный средний прирост в этот период составил 35,72%, что свидетельствует о быстром развитии и внедрении биометрических технологий в различных секторах [27]. На конец 2018 года объем рынка достиг 5,6 млрд рублей. Этот рост объясняется как увеличением спроса на биометрические технологии со стороны коммерческих и государственных организаций, так и активным развитием технологий в этой области. Указанная динамика существенно выше среднемировых показателей и подчеркивает растущее значение биометрических технологий в России. Это увеличение способствует дальнейшему развитию и интеграции биометрических систем во многие аспекты общественной жизни, в частности в безопасность, финансовые услуги и потребительские технологии.

Среди ключевых тенденций рынка выделяются:

- снижение ошибок I и II рода, увеличение скорости распознавания и сравнения;
- удобство использования и интеграции в клиентские сервисы стимулирует развитие технологий удаленной идентификации;
- сочетание биометрии с небιοметрическими данными (например, PIN/карта) или использование мультибиометрических систем для повышения надежности.

На российском рынке преобладают следующие биометрические технологии:

- распознавание отпечатков пальцев, которое широко распространено в системах контроля доступа и криминалистике, но уступает по надежности и скорости идентификации другим технологиям;
- васкулярное сканирование, наращивающее долю на рынке благодаря более высокой надежности по сравнению с отпечатками пальцев и лицевой биометрией; однако ограничено в удаленных системах идентификации из-за своей «контактности»;
- распознавание лиц, имеющее преимущества в простоте и скорости сбора данных, бесконтактности, возможности реализации идентификации

- «в потоке» и удаленных систем; не требует специализированного оборудования;
- распознавание голоса — наименее надежная и уязвимая к изменениям внешних условий технология, остается нишевым продуктом;
- аутентификация по радужной оболочке глаза — самая надежная технология, однако из-за высокой стоимости не получила массового распространения.

При этом распознавание лиц занимает наибольшую долю на российском рынке, что отличает его от мирового, где преобладает Fingerprint. В 2018 году доля этого сегмента составила 49,6% от всего рынка. В отличие от мирового рынка, где доминируют «пальчиковые» технологии, в России развитие шло в направлении лицевой биометрии. Российские компании стали одними из лучших в мире в области систем распознавания лиц.

Общий анализ коммерческих систем распознавания человека в России выявляет растущую долю систем идентификации людей на рынке, подкрепленную технологическими инновациями и государственной поддержкой. В то же время разнообразие доступных технологий показывает динамичность и адаптивность рынка к изменяющимся требованиям безопасности и идентификации.

1.4 Математическая постановка задачи

В рамках данного исследования ставится задача создания алгоритмического комплекса для распознавания и реидентификации человека на основе изображений, полученных из разнообразных источников. Основная цель — разработать набор математических функций и процедур, которые обеспечивают точное выделение, анализ и синтез ключевых признаков человека, представленного на изображениях. Это включает в себя функции детектирования силуэтов и лиц, функции преобразования выделенных объектов в векторы признаков, а также разработку методов комбинирования и идентификации на основе этих векторов. Основным вызовом здесь является не только точность детектирования и распознавания, но и оптимизация вычислительных процессов для обработки больших объемов данных.

Дано:

– множество изображений

$$\mathcal{I} = \{I_i\}_{i=1}^{N_I}, \quad (1.5)$$

где каждое изображение I_i содержит одного или несколько людей;

- функция детектирования силуэта $D_h(\cdot)$, возвращающая множество силуэтов B_h для изображения I ;
- функция детектирования лица $D_f(\cdot)$, возвращающая множество лиц B_f для изображения I или пустое множество, если лицо не обнаружено;
- функция извлечения признаков $\Phi(\cdot)$, преобразующая детектированный объект (силуэт или лицо) в вектор в пространстве признаков.

Необходимо:

1. разработать функцию комбинирования $g(\cdot)$, которая принимает на вход вектор силуэта s и вектор лица f (если лицо было обнаружено) и возвращает комбинированный вектор признаков z :

$$z = g(s, f); \quad (1.6)$$

2. разработать функцию идентификации $A(\cdot)$, которая принимает на вход комбинированный вектор признаков z и базу данных векторов DB и возвращает результат идентификации.

Задача. Построить систему, которая, принимая на вход изображение I , выполняет следующие шаги:

1. детектирование силуэта и лица на изображении I с использованием функций D_h и D_f :

$$B_h = D_h(I), \quad B_f = D_f(I); \quad (1.7)$$

2. преобразование детектированных объектов в векторы с помощью функции $\Phi(\cdot)$:

$$s = \Phi(\text{ROI}_{\text{human}}), \quad (1.8)$$

$$f = \Phi(\text{ROI}_{\text{face}}); \quad (1.9)$$

3. комбинирование векторов согласно (1.6);
4. идентификацию на основе комбинированного вектора признаков с использованием функции $A(\cdot)$ по базе DB .

Цель: минимизировать ошибку идентификации при оптимальных вычислительных затратах. Это включает в себя определение оптимальной структуры и параметров для функций D_h , D_f , Φ , g и A , а также выбор наиболее подходящих

алгоритмов машинного обучения и техник оптимизации для достижения поставленной цели.

1.5 Выводы по главе

В главе последовательно рассмотрены методы и алгоритмы, составляющие полный контур информационно-поисковой обработки видеоданных в задачах поиска и реидентификации человека. Проанализированы современные подходы к детектированию человеческих фигур и лиц, особенности локализации лица внутри силуэта как критического частного случая, а также архитектуры построения признаковых представлений для обеих модальностей. Отдельное внимание уделено метрикам обучения и сопоставления, которые определяют корректность идентификации и реидентификации, и стратегиям интеграции многомодальных признаков. Рассмотрены общепринятые наборы данных и процедуры оценки качества, закрепляющие воспроизводимость результатов и сопоставимость с базовыми решениями.

Проведенный анализ существующих решений показал ключевую роль детектирования как входного фильтра контура. Установлено, что неточности на этапе локализации объектов приводят к каскадному ухудшению качества на последующих стадиях, искажают построение эмбедингов и снижают точность сопоставления. Показано, что однофакторные схемы, опирающиеся исключительно на лицевые либо исключительно на силуэтные признаки, недостаточно устойчивы в условиях изменчивой сцены: вариации ракурса и освещения, окклюзии и неполная видимость приводят к росту ложных тревог и пропусков. Выявлено, что современные архитектуры для формирования признаковых представлений обеспечивают более высокую дискриминативность при соблюдении требований к регуляризации и объему данных, однако их применение должно быть согласовано с вычислительными ограничениями системы, ориентированной на работу в реальном времени.

Сопоставление подходов позволило зафиксировать их преимущества и ограничения. К достоинствам многофакторных схем относится повышенная устойчивость к внешним возмущениям и способность компенсировать частичные отказы модальностей, что выражается в росте интегральных метрик качества.

Вместе с тем тяжелые модели детектирования и эмбединга увеличивают задержки и нагрузку на вычислительные ресурсы; фиксированные веса при слиянии модальностей оказываются неадаптивными к смене условий съемки, а каскадный характер контура усиливает влияние ошибок начального этапа. Таким образом, практическая применимость решений определяется не только точностью отдельных алгоритмов, но и их согласованной работой под эксплуатационные метрики информационно-поисковой системы.

Суммарный анализ выявил методологический разрыв между требованиями эксплуатации и свойствами распространенных схем. Для его преодоления требуется, во-первых, усилить этап детектирования, включая обработку сценариев вложенного поиска лиц внутри силуэта; во-вторых, обеспечить построение компактных и устойчивых признаковых представлений для лица и силуэта с учетом доменных факторов; в-третьих, применять адаптивную интеграцию модальностей, учитывающую надежность и доступность источников признаков в конкретной сцене; в-четвертых, формулировать и оптимизировать целевые функции, напрямую связанные с эксплуатационными метриками (mAP, Rank-k, ROC/PR) при соблюдении ограничений по времени отклика.

Сформулированные выводы определяют содержание последующих разделов работы: разработку методики детектирования, ориентированной на снижение каскадных ошибок; построение эмбедингов для обеих модальностей с требуемой дискриминативностью и компактностью; разработку алгоритмов автоматической настройки ключевых гиперпараметров; реализацию вероятностной, по сути байесовской, интеграции признаков, адаптирующей вклад модальностей к контексту сцены; а также экспериментальную верификацию на репрезентативных наборах данных с отчетными метриками и анализом уверенности решений. В совокупности эти элементы создают основу для последующего повышения точности поиска и реидентификации человека при рациональных вычислительных затратах.

Глава 2. Методика распознавания и реидентификации человека

Опираясь на результаты анализа, представленные в первой главе, в данной главе предлагается комплексная методика решения задачи поиска и реидентификации человека в видеопотоках. Методика включает три взаимосвязанных компонента: методику детектирования лиц и силуэтов, обеспечивающую корректную локализацию объектов интереса в различных сценах и условиях съемки; методику формирования признаковых представлений (эмбеддингов) для лицевой и силуэтной модальностей, ориентированную на устойчивую дискриминацию при вариативности ракурса, освещения и окклюзий; алгоритм настройки гиперпараметров комбинированной метрики, обеспечивающий адаптивное взвешивание вклада модальностей и согласование качества распознавания с эксплуатационными ограничениями по времени отклика и ресурсам. Совместное использование указанных компонентов образует единый контур обработки, в котором точность последующих этапов опирается на качество детектирования, а итоговое решение формируется посредством вероятностной интеграции информативных признаков с учетом их текущей надежности.

2.1 Методика детектирования силуэтов и лиц

Методика детектирования силуэтов и лиц является ключевым компонентом в процессе распознавания и реидентификации человека. Основная задача на этом этапе — эффективно определить и выделить силуэты человека на изображениях. Для этой цели применяются алгоритмы глубокого обучения, способные обрабатывать и анализировать сложные визуальные данные.

2.1.1 Детектор YOLOv8

Для задачи обнаружения силуэтов и лиц в рамках разработки методики распознавания и реидентификации человека был выбран YOLOv8 [37] — одна

из самых современных моделей в сфере компьютерного зрения. YOLOv8 выделяется способностью к быстрому и точному обнаружению объектов, что делает ее особенно привлекательной для задач, требующих реального времени обработки. Эта модель, хотя и не имеет на момент написания работы официального описания, уже зарекомендовала себя в научном сообществе как новый эталон обнаружения объектов. Ее основное преимущество — высокие значения mAP (средняя точность обнаружения) и низкая задержка обработки данных, особенно заметная при тестировании на датасете COCO.

Выбор архитектуры YOLOv8 обусловлен сочетанием высокой точности и пропускной способности при умеренных вычислительных затратах, что критично для контура «детектирование, построение признаковых представлений, реидентификация» в условиях реального времени. Современные реализации следят за устойчивостью локализации на сложных сценах (плотные сцены, частичные окклюзии, вариативное освещение) и обеспечивают стабильно высокие показатели качества на классических наборах задач объектной детекции при доступности облегченных конфигураций модели, пригодных для практического развертывания. Кроме того, экосистема Ultralytics предусматривает «из коробки» сопряжение детектора с трекерами уровня BoT-SORT/ByteTrack и включение ReID-модуля (appearance-matching) на этапе ассоциации треков, что упрощает интеграцию YOLOv8 в конвейер поиска и реидентификации человека: параметры трекера содержат явные пороги по близости и «внешности», а опция `with_reid` активирует использование признаковых представлений для связывания траекторий через окклюзии и пропуски. Это делает связку «YOLOv8 + трекер с ReID» практическим стандартом для прикладных систем видеоаналитики.

Эффективность такого контура подтверждается прикладными и исследовательскими разработками, в которых YOLOv8 используется как детектор в системах отслеживания и реидентификации: публичные конвейеры демонстрируют связку YOLOv8 (детекция) + Deep/BoT-SORT (трекинг) + OSNet/классификационная голова (ReID) с устойчивым сопровождением идентификаторов через временные пропуски и взаимные перекрытия объектов; в ряде проектов дополнительно задействуются лицевые веса и позная конфигурация YOLOv8 для повышения надежности на человеческих целях. Эти решения иллюстрируют практическую применимость выбранной архитектуры в контексте реидентификации как завершающего этапа информационно-поискового контура.

Публикации по BoT-SORT показывают, что включение ReID-признаков на этапе ассоциации треков существенно повышает метрики IDF1/HOTA на классических бенчмарках MOTChallenge, что опосредованно подтверждает корректность выбора связки «точный детектор + appearance-модель». При использовании в роли детектора YOLO-семейства (включая YOLOv8) такой конвейер обеспечивает баланс между качеством и скоростью, необходимый для эксплуатации.

В совокупности эти факторы обосновывают применение YOLOv8 как базовой архитектуры детектирования в заявленной методике: модель дает качественные входные данные для построения эмбедингов, органично встраивается в трекингово-ReID-контур и обеспечивает требуемые показатели точности/задержки при реальной нагрузке.

YOLOv8 как инновационная модель обнаружения объектов специально адаптирована для выполнения задач детектирования силуэтов и лиц. Основным отличием от предшественников является улучшенная способность к обучению на разнообразных данных, обеспечивающая выявление более абстрактных и сложных визуальных паттернов. Это достигается за счет обучения на большом и многообразном наборе данных, включающем различные категории объектов. Такой подход обеспечивает лучшую адаптацию модели к реальным условиям и различным сценариям распознавания, что особенно важно при идентификации силуэтов и лиц в сложных и динамичных условиях.

На рис. 2.1 представлена детальная архитектура YOLOv8. Эта модель развивает концепцию, заложенную в YOLOv5, но с некоторыми модификациями, в частности в модуле CSPLayer, теперь именуемом как модуль C2f. Модуль C2f (cross-stage partial bottleneck с двумя сверточными слоями) объединяет высокоуровневые особенности с контекстуальной информацией, что способствует повышению точности детектирования. YOLOv8 представляет собой модель без якорей (anchor-free) с отдельными блоками обработки для определения наличия объекта, классификации и регрессии. Такой дизайн обеспечивает специализацию каждой ветви на своей задаче, улучшая общую точность модели. В выходном слое YOLOv8 используется сигмоидная функция активации для оценки вероятности наличия объекта в ограничивающей рамке. Для вероятностей принадлежности объектов к классам применяется функция softmax.

YOLOv8 использует функции потерь CIoU и DFL для определения потерь ограничивающей рамки и бинарную кросс-энтропию для классификации. Эти функции потерь обеспечивают улучшенную производительность детектирова-




Рисунок 2.1 — Схема архитектуры YOLOv8

ния, особенно при работе с мелкими объектами. Кроме того, YOLOv8 предлагает модель семантической сегментации, YOLOv8-Seg. В ней в качестве основы используется извлекатель признаков CSPDarknet53, за которым следует модуль C2f вместо традиционной архитектуры «шеи» YOLO. За модулем C2f расположены две головы сегментации, обученные предсказывать маски семантической сегментации для входного изображения. YOLOv8-Seg обеспечивает выдающиеся результаты на различных бенчмарках по детектированию объектов и семантической сегментации, сохраняя при этом высокую скорость и эффективность.

Обобщенная функция потерь и процедура обновления весов записываются следующим образом. Уравнение для определения скорости обучения:

$$\eta_t = \eta_0 \gamma^t, \quad (2.1)$$

где η_0 — начальная скорость обучения, $\gamma \in (0, 1]$ — коэффициент затухания, t — номер итерации.

Правило обновления весов:

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}(\theta_t), \quad (2.2)$$

где θ — параметры модели, $\mathcal{L}$ — функция потерь.

Конкретная функция потерь YOLOv8 определяется следующим образом:

$$\mathcal{L}_{\text{YOLO}} = \lambda_{\text{box}} \mathcal{L}_{\text{CIoU}} + \lambda_{\text{cls}} \mathcal{L}_{\text{BCE}} + \lambda_{\text{dfl}} \mathcal{L}_{\text{DFL}}, \quad (2.3)$$

где $\mathcal{L}_{\text{CIoU}}$ — потери на ограничивающей рамке, $\mathcal{L}_{\text{BCE}}$ — бинарная кросс-энтропия для многоклассовой классификации, $\mathcal{L}_{\text{DFL}}$ — distribution focal loss; $\lambda_{\text{box}}, \lambda_{\text{cls}}, \lambda_{\text{dfl}}$ — весовые коэффициенты компонентов.

Потери CIoU вычисляются как:

$$\mathcal{L}_{\text{CIoU}} = \frac{1}{N_{\text{pred}}} \sum_{i=1}^{N_{\text{pred}}} \mathbb{I}_{\text{obj}}(i) \left[1 - \text{IoU}(\hat{B}_i, B_i) + \frac{\rho^2(\hat{c}_i, c_i)}{d_i^2} + \alpha v_i \right], \quad (2.4)$$

где N_{pred} — общее количество ячеек, содержащих объект; $\mathbb{I}_{\text{obj}}(i)$ — индикаторная функция для ячеек, содержащих объект; $\hat{B}_i$ — предсказанная ограничивающая рамка; B_i — истинная ограничивающая рамка; $\hat{c}_i, c_i$ — центры рамок; ρ^2 — квадрат евклидова расстояния; d_i — диагональ наименьшей охватывающей рамки; α, v_i — коэффициенты учета соотношения сторон.

Эта функция потерь включает в себя потери CIoU для точности ограничивающей рамки, стандартную двоичную кросс-энтропию для многоклассовой классификации и распределенный фокусный потерь.

Протестированный на наборе данных MS COCO test-dev 2017, YOLOv8x показал точность AP 53,9% при размере изображения 640 пикселей (по сравнению с 50,7% у YOLOv5 при том же размере входа), при этом скорость составила 280 кадров в секунду на NVIDIA A100 и TensorRT.

2.1.2 Функции потерь для детектирования лиц и силуэтов людей

В рамках улучшения методики распознавания и реидентификации человека была разработана новая функция потерь, направленная на более точное детектирование лиц внутри силуэтов. Эта модификация функции потерь учитывает не только общие характеристики объекта, но и специфику расположения лица

в пределах силуэта. Разработка усовершенствованной функции потерь для детектирования лиц в силуэтах включает в себя интеграцию нового компонента в стандартную функцию потерь модели YOLOv8. Формула новой функции потерь имеет вид:

$$\mathcal{L} = \mathcal{L}_0 + \lambda_{\text{face}} \frac{1}{N_{\text{pred}}} \sum_{i=1}^{N_{\text{pred}}} \mathbb{I}_{\text{face}}(i) \mathcal{L}_{\text{face}}(i), \quad (2.5)$$

где $\mathcal{L}_0$ обозначает исходную функцию потерь YOLOv8; λ_{face} — коэффициент, задающий вес нового компонента в общей функции потерь; N_{pred} — общее количество ячеек с объектами; $\mathbb{I}_{\text{face}}(i)$ — индикаторная функция, определяющая, содержит ли i -я ячейка лицо; $\mathcal{L}_{\text{face}}(i)$ — компонент функции потерь для детекции лица внутри ограничивающей рамки силуэта.

Основной принцип работы новой функции потерь заключается в повышении точности идентификации лиц в сложных сценариях. Это достигается за счет штрафования модели в случаях неправильного обнаружения лиц внутри силуэта или их отсутствия, когда они ожидалась. Таким образом, модель становится более чувствительной к положению лица в рамках силуэта, что повышает общую точность системы распознавания. Новая функция потерь разработана на основе понимания динамических условий визуального распознавания лиц. Она учитывает ряд критически важных факторов: частичное закрытие лица, нестандартные углы наблюдения и переменную освещенность. Теоретически такой подход повышает чувствительность модели к мелким деталям и улучшает ее способность к распознаванию лиц в менее очевидных или прямых сценариях.

Внедрение новой функции потерь обеспечивает улучшение общей производительности системы в следующих аспектах:

- основное предназначение новой функции потерь — улучшение точности идентификации лиц в условиях, где традиционные модели могут испытывать затруднения (например, при частично закрытом лице);
- в условиях быстрого изменения сцен (например, в местах массового скопления людей), где лица могут появляться и исчезать в кадре, новая функция потерь помогает модели быстрее адаптироваться к изменениям и эффективнее идентифицировать лица;
- путем штрафования за ошибки детектирования вне силуэтов или пропуска лиц, когда они должны быть обнаружены, функция потерь способствует снижению ложных положительных и отрицательных срабатываний.

2.2 Байесовская модель объединения признаковых представлений в задаче реидентификации личности

В отличие от традиционных подходов, опирающихся на один биометрический фактор, разработана универсальная методика объединения признаков, полученных из разных источников информации. В основе метода лежит вероятностная модель, реализующая объединение признаков в пространстве решений по правилу байесовского вывода. Каждый признак рассматривается как наблюдение, аппроксимируемое нормальным распределением с параметрами, оцениваемыми по обучающим данным. Принятие решения осуществляется путем максимизации апостериорной вероятности принадлежности объекта к одной из известных личностей. В качестве средств извлечения признаков используются модели на основе архитектур с механизмами внимания, обеспечивающие устойчивость к искажениям. Проведено сравнение с методом линейного объединения признаков. Результаты экспериментов на открытом наборе данных демонстрируют повышение точности идентификации, устойчивость к частичному отсутствию данных и возможность количественной оценки степени достоверности принимаемого решения, что актуально для применения в системах обеспечения безопасности.

Реидентификация человека (person re-identification, ReID) — задача поиска и распознавания одного и того же человека на различных снимках или в разных камерах наблюдения [72]. Актуальность ReID обусловлена активным развитием систем видеонаблюдения и вопросами безопасности: автоматическое отслеживание перемещений подозреваемых, поиск пропавших людей и т. п. [33].

Традиционно ReID опирается либо на биометрию лица, либо на общие признаки фигуры (силуэт, одежда) человека по отдельности. Однако, только на одном источнике (лицо или тело) достичь высокой надежности распознавания сложно из-за вариаций позы, освещения, разрешения и перекрытий. Совмещение нескольких биометрических признаков повышает точность за счет взаимодополняющей информации различных модальностей [37; 38].

В частности, силуэт человека считается почти таким же уникальным, как и лицо, и уже используется на практике. Так, новейшие отечественные системы умного видеонаблюдения отслеживают траекторию по силуэтам и осуществляют поиск по фигуре в реальном времени [73]. Вместе с тем возникает вопрос эффективной интеграции разнородных признаков.

Наиболее простой подход объединения признаков — линейная комбинация, например, конкатенация векторов лица и тела или усреднение оценок совпадения [38]. Однако жесткое фиксированное слияние имеет ряд ограничений. Во-первых, оно не учитывает надежность каждой модальности: «шумные» данные (например, размытое лицо или скрытая одежда) могут снижать итоговую точность, тогда как оптимально было бы придать им меньший вес. Во-вторых, линейное слияние не отражает вероятностную природу биометрических измерений и не дает информации о степени уверенности. В результате система может ошибаться в условиях искаженного входа, не имея механизма выражения неуверенности в принятом решении.

В данной работе впервые предлагается использовать вероятностную модель на основе теоремы Байеса для объединения многомодальных представлений лица и тела. Научная новизна заключается в том, что байесовский подход обеспечивает адаптивное взвешивание вклада каждой модальности через апостериорную вероятность, повышая устойчивость системы к шуму, изменению условий съемки и отсутствию одного из биометрических факторов.

В работе представлены:

- a) формальная модель и алгоритм байесовской интеграции признаков;
- b) ее программная реализация с использованием современных архитектур сверточных нейронных сетей (ArcFace и трансформер Vision Transformer);
- c) экспериментальное сравнение с традиционным линейным подходом на открытом датасете.

2.2.1 Реидентификация по лицу и телу

Задача распознавания лица по изображениям длительное время развивалась независимо от задачи ReID по силуэту, формируя собственные подходы и методы. С появлением глубоких нейросетей были достигнуты выдающиеся результаты: так, архитектура FaceNet с триплетным обучением [74] достигла точности 99,6% на эталонном датасете LFW.

В дальнейшем были предложены специальные функции потерь, направленные на повышение дискриминативности векторов лица. Одной из наиболее

эффективных стала функция ArcFace [75], которая вводит аддитивную угловую margin-поправку в классификационное обучение, обеспечивая более плотные кластеры векторов для каждого человека. Сегодня ArcFace де-факто является стандартом в задачах распознавания лиц; его эффективность подтверждена как зарубежными, так и отечественными исследованиями [28].

Тем не менее даже лучшие модели распознавания лиц могут давать сбои в условиях неконтролируемой съемки — при низком разрешении, поворотах головы, частичном закрытии лица (маски, шарфы) [28]. В частности, отечественные работы отмечают снижение качества на «нетипичных» лицах, существенно отличающихся от доминирующих в обучающих данных (например, лица детей или представителей редких рас) [76], и предлагают методы предварительной фильтрации «сложных» случаев для повышения надежности. Одновременно со стороны ReID по фигуре также наблюдается значительный прогресс. Классические подходы опирались на признаки внешнего вида: цветовые гистограммы, HOG-описатели, локальные инвариантные признаки и другие [72]. С развитием глубокого обучения акцент сместился на обучаемые вектора изображений полного роста человека [33].

Архитектуры на основе сверточных нейронных сетей (например, ResNet-50) обучаются либо классифицировать идентичности в тренировочном наборе с использованием функции Softmax, либо непосредственно оптимизировать вектора с помощью метрического обучения (триплет-лосс, контрастивный лосс и т. п.) [77]. Для повышения устойчивости к вариациям позы используются стратегии деления тела на части и механизмы внимания.

Так, Harmonious Attention Network (HAN) объединяет пространственное и каналовое внимание для выделения наиболее информативных областей изображения человека [74]. Другие работы задействуют скелетную позу как условие для объединения признаков или применяют графовые нейронные сети (Graph Convolutional Networks, GCN) для моделирования взаимосвязей между частями тела и визуальными атрибутами [39].

В целом современные модели person re-identification демонстрируют высокое качество на стандартных бенчмарках (Market-1501, MSMT17 и др.), особенно при использовании нескольких масштабов и агрегации локальных признаков частей тела [78]. Тем не менее большинство существующих решений опираются исключительно на визуальную модальность — внешний вид человека.

2.2.2 Интеграция многомодальных биометрических признаков

Комбинация признаков лица и полного силуэта представляет собой мультибиометрический подход к идентификации. Еще в ранних работах отмечалось, что объединение нескольких биометрических идентификаторов (например, лица, радужной оболочки, голоса) повышает общую точность системы за счет разнообразности используемых источников.

В задаче ReID предпринимались различные подходы к multi-modal fusion на разных уровнях. Простейший из них — объединение на уровне признаков: например, конкатенация векторов лица и тела с последующей классификацией или вычислением расстояний [38]. Такой метод использован в работе [40], где отдельные нейросети извлекают признаки лица (FaceNet) и тела (OSNet), после чего векторы объединяются и сравниваются с эталонными комбинациями; авторы демонстрируют прирост порядка 5% в метрике Rank-1 по сравнению с использованием только тела.

Более сложные схемы реализуют слияние на уровне оценок (score-level fusion), например посредством усреднения или обучаемого взвешивания сходства между лицом и фигурой [38]. В системах высокого уровня применяются также байесовские сети доверия, где выходы детектора лица и дополнительная информация (пол, возраст, рост) интегрируются для повышения надежности идентификации в робототехнических приложениях [72].

Важным направлением является применение механизмов перекрестного внимания между модальностями, обеспечивающих самостоятельное выявление моделью того, каким признакам следует уделять больше внимания. В недавней работе [33], объединяющей визуальные и языковые описания, демонстрируется улучшение ReID за счет одновременного использования лица и тела: на основе изображения генерируется текстовое описание, и модули внимания сопоставляют текст с соответствующими областями (лицо, тело) на изображении, обеспечивая более полную идентификацию.

Графовые подходы, в частности основанные на GCN, представляют мультимодальные признаки в виде графа, где узлы соответствуют векторам разных модальностей одного человека, а ребра отражают их принадлежность к одной личности [21]. Обучение такого графа обеспечивает эффективное распространение информации между модальностями.

В большинстве рассмотренных подходов (за исключением байесовских) интеграция осуществляется либо через обучаемые веса (что по сути имитирует байесовский вывод, но неявно), либо через механизмы внимания. Однако явная вероятностная интеграция по правилу Байеса до сих пор не применялась для слияния векторов лица и тела. Между тем в смежных областях байесовские методы доказали свою эффективность при принятии решений на основе нескольких источников информации [38]. В данной работе восполняется этот пробел путем предложения явной байесовской модели для объединения векторов в задаче ReID.

Таким образом, предложенный подход концептуально близок к мультибиометрическим системам, осуществляющим объединение признаков на уровне принятия решения. Однако в отличие от существующих решений он основан не на эвристических или обучаемых весах, а на строгом байесовском выводе.

Разработанная схема может быть интерпретирована как наивный байесовский классификатор идентичности, в котором признаками выступают векторы лица и силуэта. Ранее наивный Байес использовался в биометрических системах для принятия решений по отпечаткам пальцев и изображениям лиц [38], но не в контексте глубоких нейросетевых векторов.

Следует также отметить, что в работе применяются современные высокоуровневые подходы — ArcFace и Vision Transformer, обеспечивающие компактное и устойчивое представление каждой модальности. Это принципиально отличает предложенный метод от более ранних работ, основанных на низкоуровневых визуальных признаках [72].

2.2.3 Байесовская модель интеграции

Задача распознавания моделируется как статистическая классификация личности y по двум наблюдениям: вектору признаков лица $\mathbf{f}$ и вектору признаков силуэта $\mathbf{s}$. Пусть y — дискретная случайная переменная, принимающая значения из множества классов идентификации Y (известных системе личностей). Тогда по теореме Байеса апостериорная вероятность того, что наблюдения $(\mathbf{f}, \mathbf{s})$

принадлежат человеку y , определяется как:

$$P(y \mid \mathbf{f}, \mathbf{s}) = \frac{P(\mathbf{f} \mid y) P(\mathbf{s} \mid y) P(y)}{\sum_{y' \in Y} P(\mathbf{f} \mid y') P(\mathbf{s} \mid y') P(y')}, \quad (2.6)$$

где $P(\mathbf{f} \mid y)$ — правдоподобие наблюдаемого признака лица при условии личности y ; $P(\mathbf{s} \mid y)$ — правдоподобие признака силуэта; $P(y)$ — априорная вероятность личности y . В настоящей работе априорно все кандидаты равновероятны (непредвзятая идентификация), поэтому далее полагается $P(y) = \text{const}$. Таким образом, решение о том, что на изображении представлен человек y^* , принимается по правилу максимума апостериорной вероятности (MAP):

$$y^* = \arg \max_{y \in Y} [\log P(\mathbf{f} \mid y) + \log P(\mathbf{s} \mid y)], \quad (2.7)$$

где переход к логарифмическим правдоподобиям заменяет произведение плотностей на сумму логарифмов и предотвращает переполнение при работе с малыми величинами вероятностей, а также обеспечивает численную устойчивость вычислений. Выражение (2.7) показывает, что решение складывается из двух логарифмических правдоподобий — от лица и от силуэта. Если, например, лицо плохо распознано (низкое $P(\mathbf{f} \mid y)$), но силуэт совпал уверенно (высокое $P(\mathbf{s} \mid y)$), то личность все равно может быть правильно определена за счет второй части. И наоборот, при противоречивых признаках будет выбран тот кандидат y , для которого произведение плотностей (или сумма логарифмов) максимизируется — то есть оба признака достаточно соответствуют этому кандидату лучше, чем любому другому. Такая схема эквивалентна наивному байесовскому классификатору, учитывающему независимые «признаковые условия» $\mathbf{f}$ и $\mathbf{s}$ для каждого класса y [38]. В настоящем случае независимость признаков лица и тела — упрощающее предположение, оправданное тем, что алгоритмы извлечения векторов обучены разделять эти признаки в различные пространства.

Для вычисления $P(\mathbf{f} \mid y)$ и $P(\mathbf{s} \mid y)$ необходимо построить вероятностную модель распределения векторов каждой модальности для каждой личности. В данном исследовании выбирается простейшая модель — многомерное нормальное распределение (гауссиана) в пространстве векторов. Предполагается, что для каждой личности y признаки лица $\mathbf{f}$ распределены нормально с некоторым средним μ_y^f и ковариационной матрицей Σ_y^f , то же верно для признаков силуэта с параметрами μ_y^s, Σ_y^s . Эти параметры можно оценить по обучающей выборке векторов (то есть по нескольким изображениям каждого человека из базы). Тогда

плотность имеет вид:

$$P(\mathbf{f} \mid y) = \frac{1}{(2\pi)^{d/2} |\Sigma_y^f|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{f} - \boldsymbol{\mu}_y^f)^T \Sigma_y^{f-1} (\mathbf{f} - \boldsymbol{\mu}_y^f)\right), \quad (2.8)$$

и аналогично для $P(\mathbf{s} \mid y)$. Здесь d — размерность пространства вектора (для ArcFace $d = 128$). На практике для устойчивости и уменьшения числа параметров возможно использование диагональной или изотропной (скалярной $\sigma^2 I$) ковариации, тогда формулы упрощаются до зависимости от евклидова или махаланобисова расстояния $\|\mathbf{f} - \boldsymbol{\mu}_y^f\|$.

Таким образом, байесовский подход в указанном упрощении сводится к распознаванию по ближайшему центроиду в объединенном пространстве, что эквивалентно взвешенному (по дисперсии) сложению признаков. Полноценная же байесовская модель (2.8) допускает задание разных ковариаций, учитывая, например, что разброс признаков лица для данной личности меньше, чем разброс признаков фигуры (что логично, так как одежда меняется).

На рис. 2.2 представлена блок-схема предлагаемого алгоритма. Сначала из входного изображения с помощью двух нейросетевых моделей извлекаются вектора: $\mathbf{f}$ — 128-мерный вектор лица и $\mathbf{s}$ — d_s -мерный вектор тела (в эксперименте $d_s = 256$).

Затем эти признаки поступают в модуль байесовского классификатора, где вычисляются правдоподобия (2.8) для каждого из N зарегистрированных в системе пользователей (личностей). Перемножая плотности (или суммируя лог-правдоподобия) согласно формуле (2.6), модуль выдает апостериорные вероятности $P(y \mid \mathbf{f}, \mathbf{s})$ по всем классам $y = 1, \dots, N$.

Финальное решение — идентификатор y^* — выбирается по максимальной апостериорной вероятности. Кроме того, вероятности могут быть использованы для оценки уверенности: если максимум $P(y^* \mid \mathbf{f}, \mathbf{s})$ низок, система может воздержаться от однозначного ответа (выдать топ- k кандидатов либо запросить дополнительный образ). Ниже приведен алгоритм байесовской идентификации.




Рисунок 2.2 — Блок-схема предлагаемого алгоритма байесовской реидентификации

Алгоритм байесовской идентификации.

Вход: изображение с лицом и фигурой человека.

Шаг 1. Извлечение признаков:

$f := \text{Embedder}_{\text{face}}(\text{изображение лица});$

$s := \text{Embedder}_{\text{body}}(\text{изображение тела}).$

Шаг 2. Байесовский классификатор:

Для каждого $y \in Y$:

$p_f(y) := P(f \mid y)$ по формуле (2.8);

$p_s(y) := P(s \mid y);$

$p(y) := p_f(y) \cdot p_s(y)$ (так как $P(y) = \text{const}$);

конец.

Шаг 3. Идентификация:

$y^* := \arg \max_{y \in Y} p(y);$

вывести y^* как опознанную личность;

при необходимости вывести $p(y^*)$ как степень уверенности.

2.2.4 Архитектура кодировщиков

На рис. 2.3 представлена архитектура Vision Transformer для извлечения признаков изображения. Входное изображение делится на патчи фиксированного размера, которые подаются в трансформерный энкодер. На выходе используется классификационный токен ([CLS]) как вектор изображения. MLP-голова отбрасывается [79].

В предлагаемом подходе применяются две нейросетевые модели (кодировщика), извлекающие векторные признаки из изображений: одна — для лица, другая — для силуэта человека. Обе модели построены на базе Vision Transformer (ViT) и используют функцию потерь ArcFace [75], доказавшую свою эффективность для задач биометрической идентификации.

Выбор архитектур эмбеддеров лиц и силуэтов выполнялся не эвристически, а на основе совокупности критериев, учитывающих специфику задачи реидентификации. В качестве базовых рассматривались три класса моделей:

- классические сверточные сети (ResNet, IR-SE, EfficientNet, GhostNet);




Рисунок 2.3 — Архитектура Vision Transformer

- облегченные архитектуры, ориентированные на работу в условиях жестких ресурсных ограничений;
- трансформерные архитектуры типа Vision Transformer (ViT) [79] с механизмами самовнимания.

Критериями отбора служили:

- дискриминативность признакового пространства (качество по mAP, SMC/Rank-k на репрезентативных наборах данных);
- устойчивость к вариациям условий съемки (ракурс, освещение, частичная окклюзия);
- вычислительная сложность (количество параметров модели, объем операций на одно изображение, задержка на целевой аппаратной платформе);
- простота дообучения и переноса на новые домены при ограниченном числе размеченных примеров.

Предварительный анализ литературы [75; 77; 79] и пробные эксперименты показали, что модели на основе ViT в сочетании с угловыми функциями потерь типа ArcFace [75] формируют более компактные и хорошо разделимые кластеры эмбедингов по сравнению с классическими сверточными архитектурами при сопоставимой вычислительной нагрузке. Это особенно выражено в условиях значительной вариативности позы и освещения, характерных для задач реидентификации. При этом для силуэтов требовалось более высокое разрешение глобальных контекстных связей, чем могут обеспечить локальные свертки фиксированного размера.

С учетом указанных обстоятельств в качестве базовых эмбеддеров для обеих модальностей выбраны архитектуры на основе Vision Transformer с L_2 -нормированием выходных векторов и функцией потерь ArcFace. Такой выбор обеспечивает баланс между дискриминативностью признаков, устойчивостью к внешним возмущениям и возможностью практического развертывания в системах, работающих вблизи реального времени.

Детальное рассмотрение архитектуры Vision Transformer принципиально важно в контексте решаемой задачи, поскольку именно способ построения токенов и организация механизма самовнимания определяют геометрию признакового пространства, в котором далее реализуется байесовский вывод. В отличие от классических сверточных сетей, ограниченных локальным полем зрения и жесткой иерархией уровней признаков, ViT изначально оперирует последовательностью патч-токенов и моделирует глобальные зависимости между всеми фрагментами изображения. Это обеспечивает следующие возможности кодировщика:

- учитывать взаиморасположение ключевых областей (лицо, плечи, торс, нижняя часть силуэта) при формировании единого эмбединга;
- естественным образом интегрировать информацию о фоне и контексте сцены, что важно для устойчивости к частичным окклюзиям и пересечению траекторий;
- реализовывать инвариантность к масштабным и геометрическим преобразованиям за счет позиционных кодировок и многоуровневого внимания.

С точки зрения реидентификации это означает, что вектор признаков $\mathbf{f}$ или $\mathbf{s}$, извлекаемый ViT, отражает не только локальные текстурные особенности (рисунк одежды, черты лица), но и конфигурацию тела в целом. Такая глобальная

репрезентация существенно улучшает разделимость классов в условиях изменяющихся поз и ракурсов, что подтверждается визуализациями t-SNE и высокими значениями mAP, полученными в экспериментальной части работы. Кроме того, использование единой архитектурной парадигмы для лица и силуэта упрощает последующую вероятностную интеграцию модальностей, так как обе последовательности признаков подчиняются сходным статистическим предпосылкам.

Для каждого изображения соответствующая модель извлекает вектор:

$$\mathbf{f} \in \mathbb{R}^{d_f}, \quad \mathbf{s} \in \mathbb{R}^{d_s}, \quad (2.9)$$

где $\mathbf{f}$ — вектор лица, $\mathbf{s}$ — вектор силуэта.

Данная архитектура разбивает изображение на непересекающиеся патчи, кодирует их в линейном пространстве и передает в стек self-attention-блоков трансформера. На выходе берется вектор [CLS] как обобщенное представление всего изображения. Такая структура эффективна как для лиц, так и для тел, что делает ее универсальной основой для обеих модальностей.

Функция потерь ArcFace [75] применяется для повышения дискриминативности представлений, вводя аддитивную угловую поправку в классификационную границу. Это обеспечивает формирование векторов в плотные и разделенные кластеры. Альтернативно в задачах re-identification может применяться Triplet Loss [77] — метрическая функция, минимизирующая расстояние между положительными парами и увеличивающая расстояние до отрицательных. Однако в проведенных в работе экспериментах ArcFace показал лучшую сходимость и стабильность обучения.

Перед вычислением плотностей вектора нормализуются по L_2 -норме:

$$\hat{\mathbf{f}} = \frac{\mathbf{f}}{\|\mathbf{f}\|_2}, \quad \hat{\mathbf{s}} = \frac{\mathbf{s}}{\|\mathbf{s}\|_2}. \quad (2.10)$$

В отличие от классического подхода центрирование признаков относительно среднего по обучающей выборке не производится, поскольку параметры многомерного нормального распределения (среднее и ковариационная матрица) для каждого класса оцениваются напрямую по обучающим данным.

Для объединения информации из разных модальностей — лица и силуэта — применяется байесовская схема. Итоговая логарифмическая апостериорная вероятность принадлежности к классу вычисляется как сумма логарифмов модальности-зависимых плотностей:

$$\log P(y \mid \hat{\mathbf{f}}, \hat{\mathbf{s}}) \propto \log P(\hat{\mathbf{f}} \mid y) + \log P(\hat{\mathbf{s}} \mid y). \quad (2.11)$$

При этом весовые коэффициенты не используются, то есть вклад каждой модальности считается равным. Эксперименты показали, что даже при равномерной агрегации признаки обеих модальностей вносят значимый вклад в классификацию, а предварительная L_2 -нормализация обеспечивает стабильную работу подхода вне зависимости от размерности векторов.

Одним из важных преимуществ предложенного байесовского подхода является его низкая вычислительная сложность и хорошая масштабируемость. В отличие от сложных методов с обучаемыми коэффициентами или методов на основе глубоких сетей с перекрестным вниманием, предложенная модель требует лишь расчета евклидовых расстояний до центроидов классов в низкоразмерных пространствах признаков, что реализуется крайне эффективно даже для больших баз идентифицируемых личностей. При увеличении количества личностей (классов) вычислительная нагрузка растет линейно, обеспечивая легкое масштабирование решения. Кроме того, подход обеспечивает простое добавление новых модальностей и адаптацию системы под изменения условий съемки без необходимости переобучения сложных глубоких архитектур.

В отличие от известных подходов к задачам person re-identification, в которых, как правило, используется либо одиночная модальность (силуэт или лицо), либо простое линейное объединение признаков [33; 38; 72], разработанный в работе метод опирается на следующие принципиальные положения.

Специализация кодировщиков под модальности. Для лиц и силуэтов используются два отдельных кодировщика на основе ViT, каждый из которых обучается с учетом специфики соответствующей модальности и функции потерь ArcFace. Это обеспечивает формирование эмбеддингов с различной «геометрией» кластеров (меньший разброс для лиц, больший — для силуэтов), что далее явным образом учитывается в байесовской модели.

Нормировка и согласование признаков пространств. Применение L_2 -нормировки (2.10) приводит эмбеддинги к единичной сфере, обеспечивая сопоставимость расстояний и корректность предположения о многомерной нормальности распределений внутри классов. Это создает основу для строгой вероятностной интерпретации, в то время как во многих работах объединение признаков носит сугубо эвристический характер.

Вероятностная интеграция вместо фиксированных весов. Вместо жестко заданного веса α при объединении признаков лица и силуэта, как это часто делается в линейных схемах, в работе используется байесовская модель (2.6)-(2.8),

в которой вклад модальностей задается через их правдоподобия. Таким образом, модальность с более устойчивым и узким распределением (например, лицо при хороших условиях съемки) автоматически оказывает больший вклад в апостериорную вероятность, тогда как «шумная» модальность (размытый силуэт, сильная окклюзия) в меньшей степени влияет на итоговое решение.

Возможность работы при отсутствии одной из модальностей. Благодаря вероятностной постановке при отсутствии лицевого или силуэтного канала классификатор может быть естественным образом приведен к учету только оставшейся модальности, что формально соответствует маргинализации по отсутствующему наблюдению. Это отличие принципиально от методов, использующих жесткое слияние векторов фиксированной размерности.

Совокупность перечисленных принципов обеспечивает превосходство разработанного подхода над существующими решениями в аспектах устойчивости к отсутствию или деградации отдельной модальности, интерпретируемости принимаемых решений и соответствия статистическим предпосылкам, лежащим в основе байесовского вывода. Результаты сравнительного анализа по метрике mAP на датасетах CUHK03, Market-1501 и MARS (см. раздел 3.3) подтверждают, что такая схема интеграции признаков обеспечивает уровень качества, сопоставимый или превосходящий state-of-the-art методы при сопоставимой вычислительной сложности.

Одним из ограничений предложенного подхода является использование предположения о нормальности распределения признаков в каждой модальности, что может не всегда идеально соответствовать реальным данным, особенно при наличии выбросов или нетипичных наблюдений. Для преодоления этого ограничения рекомендуется в дальнейшем рассмотреть применение более гибких статистических моделей, в частности смесей гауссовых распределений или непараметрических методов оценки плотностей. Также можно рассмотреть устойчивость модели к шумам и искажениям в данных и возможности ее улучшения через использование робастных статистических методов или предварительной фильтрации входных данных.

Дальнейшие направления работы связаны с расширением модели несколькими биометрическими модальностями и внедрением более гибких ковариационных структур, обеспечивающих учет попарной зависимости признаков. Также перспективно исследовать онлайн-обучение параметров распределений для под-

держки динамических баз персоналий и адаптацию порога уверенности под изменяющиеся условия съемки.

2.3 Выводы по главе

Во второй главе продемонстрирован комплексный подход к распознаванию и реидентификации человека, основанный на современных алгоритмах компьютерного зрения и методах глубокого обучения. Важнейшим этапом становится детектирование силуэтов и лиц, для чего предложено использовать модель YOLOv8, обладающую высокой скоростью обработки и точностью определения объектов. Модификация стандартной функции потерь, учитывающая специфику обнаружения лиц внутри силуэтов, обеспечивает более точный поиск ключевых областей на изображении, особенно в сложных и динамичных сценах. Это снижает количество ложных срабатываний и повышает надежность идентификации даже при наличии частичных перекрытий или нетривиальных условий освещения.

Следующим существенным шагом является формирование эмбедингов, то есть числовых векторных представлений лиц и силуэтов. Внимание уделено разнообразным архитектурам — от классических сверточных сетей (ResNet, IR-SE, GhostNet, EfficientNet) до Vision Transformer (ViT). Выбор ViT обоснован ее способностью улавливать глобальные контекстные взаимосвязи на изображении, что особенно важно при анализе неоднородных входных данных. Наличие гибких механизмов внимания и возможность масштабирования делают ViT перспективным инструментом для формирования информативных эмбедингов в задачах реидентификации.

Основой методики реидентификации стало объединение (комбинирование) эмбедингов лиц и силуэтов с использованием байесовской вероятностной модели и MAP-критерия. Подобная стратегия обеспечивает более полное описание объекта и повышает точность распознавания. Адаптивный вклад каждой модальности достигается через ковариационные матрицы класса в гауссовых правдоподобиях, что устраняет необходимость в ручной настройке весовых коэффициентов и обеспечивает корректное поведение решающего правила при временном отсутствии или зашумлении одной из модальностей.

В заключительной части главы рассмотрены вопросы разработки и оптимизации комбинационной метрики для идентификации, подтверждена сходимость, детерминированность и массовость предложенного алгоритма. Сходимость объясняется линейностью структуры метода и прекращением его работы при достижении оптимального или граничного значения параметров. Детерминированность обеспечивается строго заданными исходными данными, а массовость — возможностью масштабировать процесс перебора на любые объемы данных при сохранении корректного функционирования алгоритма. Таким образом, глава демонстрирует комплексный подход, совмещающий передовые средства детектирования, формирования эмбеддингов и метрики идентификации, что открывает перспективы для высокоточных систем распознавания и реидентификации человека.

В ходе разработки частных методик и алгоритмов возник ряд проблем, обусловленных как характеристиками исходных данных, так и ограничениями целевой эксплуатационной среды информационно-поисковой системы. Ниже последовательно изложены ключевые трудности и примененные решения в контексте детектирования, формирования признаковых представлений и настройки гиперпараметров комбинированной метрики с последующей интеграцией модальностей.

На этапе детектирования основными источниками ошибок стали сложные сцены с высокой плотностью объектов, вариативным освещением и частичными перекрытиями, а также случаи, когда лицо присутствует как «вложенная» область внутри силуэта и фиксируется под нестандартными ракурсами. Это приводило к каскадному эффекту: ошибочная локализация формировала некорректные входные данные для дальнейших этапов. Для снижения влияния указанных факторов усилена часть, отвечающая за качество локализации: проведена донастройка детектора на доменно близких выборках с акцентом на «трудные» примеры (окклюзии, слабое освещение), модифицирована функция потерь с увеличением веса ошибок по мелким лицевым областям и введены дополнительные проверки согласованности между маской силуэта и найденным лицом. Дополнительно применены процедуры калибровки порогов постобработки (NMS/score-threshold) и адаптивной фильтрации по контекстным признакам сцены, что снизило количество пропусков и ложных срабатываний без существенного роста вычислительных затрат.

При построении признаковых представлений для лица и силуэта выявлены два класса проблем: (1) падение дискриминативности при сильной вариативности ракурса и позы; (2) переобучение на ограниченных фрагментах данных. Для решения первой проблемы применены архитектурные и процедурные меры: нормализация входов, усиленные аугментации (в том числе имитация освещенности/окклюзий), а также согласование размеров и центров обрезки (crop) с характерными зонами информативности для каждой модальности. Для борьбы с переобучением использованы регуляризация с контролем нормы весов и признаков, label-smoothing для стабилизации градиентов, а при обучении метрик — комбинации Triplet/ArcFace-подобных потерь, обеспечивающие разнесение межклассовых расстояний при контролируемой компактности внутриклассовых кластеров. На валидации проводился контроль по интегральным метрикам (mAP, CMC/Rank-k) и анализу распределений скоров, что позволило своевременно выявлять деградацию обобщающей способности.

Существенные трудности возникали при выборе весов для объединения лицевых и силуэтных признаков: фиксированные коэффициенты демонстрировали нестабильность при смене сцены и условий съемки. Для снятия этой проблемы разработан алгоритм автоматической настройки ключевого гиперпараметра комбинированной метрики, учитывающий показатели качества детектирования и локальные признаки надежности модальности. Использована вероятностная (байесовская) схема интеграции, в которой вклад модальностей масштабируется их текущей достоверностью: при уверенной локализации лица возрастает вес лицевого признакового вектора, при частичной видимости — приоритет смещается в сторону силуэта. Такой подход обеспечил адаптацию решения к контексту кадра без ручной подстройки и рост итоговых показателей при сопоставимой вычислительной сложности.

В рамках требований близкой к реальному времени обработки выявлена проблема избыточной задержки при использовании тяжелых конфигураций детектора и эмбеддера. Для ее разрешения выполнено профилирование конвейера с последующей оптимизацией узких мест: упорядочивание вычислений с уменьшением межэтапных копирований, квантизация некоторых промежуточных представлений, а также ограничение числа кандидатов после детектирования на основе доверия и геометрии. Пороговые значения решений согласованы с эксплуатационными метриками (ROC/PR-анализ, оптимизация по F-мере в зоне интереса), что обеспечило баланс между точностью и временем отклика.

Отмеченные шумы разметки и дисбаланс классов осложняли объективную оценку качества. Для их компенсации проведены очистка и стратифицированные выборки, а также перекрестная валидация с отчетными доверительными интервалами для ключевых метрик. Единообразные протоколы предобработки, фиксированные генераторы случайных чисел и сохранение контрольных конфигураций обеспечили воспроизводимость результатов и сопоставимость с базовыми методами.

В совокупности изложенные меры устранили критичные узкие места контура и обеспечили согласованную работу компонентов: детектор формирует корректные входы, эмбединги сохраняют дискриминативность в сложных условиях, а адаптивная интеграция модальностей повышает устойчивость итогового решения без выхода за рамки допустимых вычислительных затрат. Полученные эффекты подтверждаются ростом интегральных показателей качества на репрезентативных наборах данных при соблюдении требований к задержке и стабильности.

Глава 3. Оценка эффективности разработанной комплексной методики

3.1 Описание экспериментальной установки и используемых данных

В рамках экспериментального исследования по детекции лиц и силуэтов людей была разработана и развернута специализированная установка, включающая последовательные этапы подготовки исходных данных, их аннотирования, предобработки и дальнейшего применения модели YOLOv8. В качестве основного источника данных использовался датасет WIDER FACE, известный своей масштабностью и разнообразием снимков, охватывающих широкий спектр ракурсов, разрешений и условий освещения. Исходные аннотации WIDER FACE были сконвертированы в формат, пригодный для обучения моделей семейства YOLO, что потребовало автоматизированного извлечения координат объектов и приведения их к нормализованному виду (центр, ширина, высота объекта относительно размеров изображения). Полученные преобразованные аннотации были структурированы в соответствии с общепринятой схемой каталогов, разделяющей тренировочные, валидационные и тестовые наборы данных, а также соответствующие им подпапки с изображениями и метаданными.

Для выполнения задачи детектирования людей (класс «человек») во валидационном наборе данных применялась предобученная версия модели YOLOv8, настроенная на идентификацию общих классов объектов. Предсказанные моделью ограничивающие рамки были дополнительно сохранены как аннотации класса «1» и объединились с ранее размеченными рамками лиц, что обеспечило единый формат описания объектов «лицо» и «силуэт». Данная унифицированная разметка впоследствии использовалась для экспериментов по распознаванию и реидентификации.

Экспериментальная установка была развернута на высокопроизводительном сервере, обеспеченном современными графическими процессорами с характеристиками, указанными в табл. 1.

Серверная инфраструктура включала все необходимые библиотеки для глубокого обучения и утилиты для управления пакетами, обеспечивающие гибкую настройку параметров эксперимента и эффективную обработку больших объемов данных.

Таблица 1 — Характеристики сервера

Параметр	Характеристика
Операционная система	Ubuntu 22.04.4 LTS x86_64
Процессор (CPU)	AMD Ryzen 9 7950X (32 ядра, 5,88 GHz)
Графические процессоры	2 × NVIDIA GeForce RTX 3090 Ti (24 ГБ)
Оперативная память (RAM)	128 ГБ
Версия NVIDIA Driver	555.42.02
Версия CUDA	12.5

3.2 Реализация подхода к детектированию лиц и силуэтов

В данном разделе рассматривается практическая реализация метода детектирования лиц и силуэтов, основанная на модифицированной функции потерь модели YOLOv8. Основная идея данного подхода заключается в учете особенностей распознавания лиц и контуров человеческих фигур в составе единой нейросетевой архитектуры. Особое внимание уделено тонкой настройке коэффициента λ_{face} в функции потерь, отвечающего за взвешивание различных компонентов при обучении модели. Ниже подробно описаны этапы экспериментов, начиная от предварительной подготовки исходных данных и заканчивая анализом полученных результатов.

3.2.1 Настройка и подготовка данных

Для обучения и валидации модифицированной модели YOLOv8 был выбран датасет WIDER Face, характеризующийся богатым разнообразием изображений, на которых присутствуют лица в разных ракурсах, разрешениях и условиях освещения. Кроме того, в наборе имеются аннотации, обеспечивающие выделение как самих лиц, так и силуэтов людей, что удовлетворяет потребностям задачи по совместному распознаванию соответствующих объектов.

Подготовка данных включала несколько последовательных этапов.

Копирование и распаковка исходных файлов. Все исходные изображения и аннотационные файлы, доступные на официальном ресурсе WIDER Face, были

скопированы на локальный сервер. Затем выполнен процесс распаковки архивов в отдельные каталоги, соответствующие подразделам набора данных (обучающая выборка и валидационная выборка).

Преобразование аннотаций в формат YOLOv8. Исходные метаданные WIDER Face, описывающие координаты объектов (лиц и силуэтов), требовали конвертации в структуру, приемлемую для обучения модели YOLOv8. В частности, каждая аннотация приводилась к виду $(x_{\text{center}}, y_{\text{center}}, w, h)$, нормализованному относительно размеров соответствующего изображения. Для автоматизации данной процедуры была написана специальная программа на Python, которая последовательно считывала исходные координаты, выполняла масштабирование и центровку, а затем генерировала файлы аннотации в соответствии с требуемым форматом.

Создание структуры каталогов для обучающих и проверочных данных. В целях унификации и соблюдения принятых в компьютерном зрении стандартов была сформирована иерархия директорий, содержащая две основные подпапки: `train` и `val`. Каждая из этих подпапок включала подкаталоги для изображений (`images`) и аннотаций (`labels`). Такой подход обеспечил быстрое и удобное взаимодействие с библиотеками глубокого обучения, а также упростил дальнейшую интеграцию в конвейер обучения YOLOv8.

Описанные шаги были оформлены в виде единой процедуры подготовки данных, представляющей собой важный элемент предлагаемой методики, а не только технический этап. Формально процедуру можно представить как отображение:

$$S: \mathcal{D}_{\text{WIDER}} \rightarrow \mathcal{D}_{\text{YOLO}}, \quad (3.1)$$

где $\mathcal{D}_{\text{WIDER}}$ — исходный набор WIDER Face с оригинальными аннотациями; $\mathcal{D}_{\text{YOLO}}$ — результирующее множество размеченных изображений в формате, пригодном для обучения YOLOv8 с учетом особенностей дальнейшей задачи ре-идентификации.

Все ограничивающие рамки приводятся к каноническому представлению $(x_{\text{center}}, y_{\text{center}}, w, h)$, нормированному на размеры изображения. Для этого исходные координаты пересчитываются и масштабируются с учетом реального разрешения, что уменьшает численные ошибки и обеспечивает корректное формирование функции потерь.

Введены пороговые ограничения на минимальный размер лица и силуэта (в долях от размеров изображения), а также проверка согласованности рамок:

слишком маленькие или вырожденные рамки, равно как и объекты, выходящие за границы изображения, исключаются из обучающей выборки. Это уменьшает долю заведомо шумных примеров, приводящих к паразитным градиентам при обучении и ухудшению обобщающей способности модели.

При формировании обучающей и валидационной подвыборок учитывается распределение размеров и поз лиц: выборка балансируется таким образом, чтобы в каждом наборе присутствовали как «простые» (крупные, фронтальные лица), так и «сложные» примеры (малые объекты, неполные профили, частичные окклюзии). Это обеспечивает репрезентативность данных относительно целевого эксплуатационного диапазона и уменьшает риск смещения модели в сторону «легких» случаев.

Для согласования с задачей совместного детектирования лиц и людей предсказанные силуэты, полученные с использованием предобученной модели YOLOv8 по общим классам, включаются в аннотации как объекты класса «human». При этом устанавливаются пороги по уверенности и IoU, исключающие ложные срабатывания. Таким образом, формируется единый набор меток для классов «face» и «human», согласованный по формату и качеству.

На этапе подготовки данных фиксируется набор геометрических и фотометрических искажений (случайные повороты, масштабирование, изменения яркости/контрастности), имитирующих типичные вариации реальных сцен. Диапазоны параметров аугментаций подбираются таким образом, чтобы не разрушать геометрию лицевых областей и силуэтов, но расширять обучающую выборку за счет генерации реалистичных вариаций. В совокупности перечисленные шаги обеспечивают не только техническую совместимость исходного датасета с реализацией YOLOv8, но и повышение эффективности обучения модели. Устранение некорректных и аномальных аннотаций снижает уровень шума в функции потерь, а стратификация по масштабу и сложности обеспечивает более равномерное освоение различных типов объектов. Это приводит к увеличению точности и полноты детектирования как для класса «face», так и для класса «human» (см. результаты в разделе 3.2.4) и создает надежную основу для последующих этапов построения эмбедингов и реидентификации.

3.2.2 Изменение функции потерь

Ниже представлена общая структура модифицированной функции потерь (BboxLoss), в которой реализован дополнительный компонент, учитывающий детекцию лиц внутри силуэтов. Основная идея заключается в том, чтобы при обучении модели YOLOv8 усиливать штраф за ошибки, связанные с неправильным обнаружением лиц, и тем самым повысить точность идентификации лиц в сложных сценах (например, при частичных перекрытиях). В результате итоговая функция потерь дополнительно содержит слагаемое, зависящее от λ_{face} , что позволяет регулировать вклад компонента лиц в общую ошибку.

Алгоритм BboxLoss(reg_max, use_dfl, lambda_face):

1. Инициализация параметров:

- reg_max: максимальное значение регуляризации;
- use_dfl: флаг использования Distribution Focal Loss (DFL);
- lambda_face: весовой коэффициент, регулирующий вклад ошибки лиц.

2. Определение функции forward(pred_dist, pred_bboxes, anchor_points,

target_bboxes, target_scores, target_scores_sum, fg_mask):

2.1. Расчет базовых весов для переднего плана:

weight := сумма target_scores по последней оси, отфильтрованных fg_mask.

2.2. Вычисление IoU и основной потери для ограничивающих рамок:

iou := IoU(pred_bboxes[fg_mask], target_bboxes[fg_mask]);

loss_iou := средневзвешенное значение $(1 - iou)$, учитывающее weight.

2.3. Если use_dfl = true, вычислить DFL-потерю:

target_ltrb := преобразование target_bboxes в формат {left, top, right, bottom};

loss_dfl := средневзвешенная DFL-потеря(pred_dist[fg_mask], target_ltrb[fg_mask]).

Иначе: loss_dfl := 0.

2.4. Расчет дополнительной ошибки для лиц:

face_mask := логическая маска объектов, соответствующих лицам (target_scores > 0,5)

и входящих в область fg_mask;

если face_mask содержит объекты лиц:

face_iou := IoU(pred_bboxes[face_mask], target_bboxes[face_mask]);

loss_face := средневзвешенное значение $(1 - face_iou)$;

иначе: loss_face := 0.

2.5. Формирование итоговой функции потерь:

total_loss := loss_iou + loss_dfl + $\lambda_{face} \cdot loss_face$.

2.6. Возвратить (total_loss, loss_dfl).

3. Вспомогательная функция _df_loss(pred_dist, target):

3.1. Преобразовать целевые значения рамок в целочисленный формат.

3.2. Определить веса weight.left, weight.right для каждого граничного значения.

3.3. Вычислить DFL-потери как усредненную кросс-энтропию по всем при-

знакам

В основе предложенного подхода лежит несколько ключевых этапов, включающих как процедуру инициализации гиперпараметров, так и вычисление различных слагаемых итоговой функции потерь. На первом этапе инициализации определяется набор параметров, среди которых следует выделить `reg_max` — он формирует распределение вероятностей для предсказываемых границ объектов, а также флаг `use_dfl`, определяющий, будет ли использоваться Distribution Focal Loss. Особое значение придается коэффициенту λ_{face} , регулирующему степень штрафа за некорректную детекцию лиц и обеспечивающему акцент на точности определения лиц в составе силуэтов.

Затем в основной функции `forward` последовательно вычисляются несколько компонентов ошибки. Сначала формируется общий вес `weight` для переднего плана, усредняющий потери только по тем фрагментам изображения, которые отмечены в маске `fg_mask`. Далее рассчитывается базовая ошибка `loss_iou`, зависящая от величины пересечения (IoU) между предсказанными и истинными ограничивающими рамками. При необходимости активируется `loss_dfl`, представляющая собой распределенную фокальную ошибку и направленная на повышение точности предсказаний, особенно в случае мелких или частично перекрытых объектов. Ключевым нововведением служит компонент `loss_face`, обеспечивающий отдельный учет ошибок при распознавании лиц в пределах силуэтов. Итоговая функция потерь `total_loss` в результате представляет собой суммарное выражение, включающее все потери.

Дополнительный метод `_dfl_loss` отвечает непосредственно за вычисление DFL-потерь, что сводит задачу прогнозирования координат ограничивающих рамок к задаче классификации по ряду «бинов», охватывающих возможные положения границ объектов. В нем выполняется преобразование целевых координат (масштабирование, округление), а также рассчитывается кросс-энтропия, учитывающая вес каждого бина.

В совокупности такая структура алгоритма обеспечивает более точное позиционирование лиц относительно силуэтов, корректируя работу модели за счет регулируемого параметра λ_{face} . Это особенно полезно в условиях, когда лица занимают лишь малую часть изображения и их корректная детекция крайне важна для последующих задач идентификации или реидентификации.

3.2.3 Экспериментальные настройки

Для комплексной оценки влияния коэффициента λ_{face} на качество детектирования лиц и силуэтов проведен ряд экспериментов с варьированием данного параметра в интервале от 0,1 до 2,7. При этом во всех сериях экспериментов использовались одинаковые исходные данные (датасет WIDER Face и соответствующие аннотации), а также идентичная конфигурация модели YOLOv8, за исключением различного значения λ_{face} . Таким образом, исключалось влияние побочных факторов, и можно было объективно сравнить эффективность метода при различных значениях данного гиперпараметра.

Каждая из моделей была обучена на одном и том же наборе данных, и результаты были оценены по метрикам Precision (P), Recall (R), mAP@0.5 и mAP@0.5:0.95.

3.2.4 Результаты и их анализ

Для оценки эффективности предлагаемой модификации функции потерь проведен ряд экспериментов с различными значениями параметра λ_{face} (от 0,1 до 2,7). В табл. 2 приведены основные показатели (Precision, Recall, mAP@0.5, mAP@0.5:0.95) как для детекции лиц (Face), так и для распознавания человека в целом (Human). Каждый из приведенных вариантов обучения основывался на одинаковом наборе данных и идентичных условиях эксперимента, что обеспечивает прямую сопоставимость результатов.

3.2.5 Графическое представление результатов

На рис. 3.1 представлены графики зависимостей различных метрик от значения λ_{face} .

В данном разделе был подробно рассмотрен процесс реализации подхода к детектированию лиц и силуэтов с использованием измененной функции по-

Таблица 2 — Сравнительная таблица результатов обучения модели при различном λ_{face}

λ_{face}	Класс «лицо»				Класс «силуэт»			
	Precision	Recall	mAP@0.5	mAP@0.5:0.95	Precision	Recall	mAP@0.5	mAP@0.5:0.95
0,1	0,900	0,603	0,714	0,395	0,829	0,902	0,939	0,837
0,4	0,899	0,606	0,716	0,397	0,825	0,905	0,940	0,837
0,8	0,901	0,607	0,719	0,399	0,830	0,902	0,940	0,836
1,0	0,896	0,609	0,718	0,399	0,825	0,905	0,940	0,835
1,3	0,903	0,603	0,718	0,400	0,832	0,900	0,940	0,833
1,6	0,900	0,608	0,720	0,401	0,826	0,904	0,939	0,834
2,0	0,907	0,607	0,723	0,402	0,829	0,900	0,939	0,832
2,5	0,903	0,610	0,722	0,402	0,827	0,903	0,940	0,833
2,7	0,901	0,611	0,723	0,402	0,825	0,900	0,938	0,830




Рисунок 3.1 — Графики зависимостей показателей качества от λ_{face}

терь модели YOLOv8. Основной целью изменений было улучшение точности детекции лиц внутри силуэтов, что достигалось добавлением нового компонента в функцию потерь. Этот компонент учитывал ошибки детекции лиц, что способствовало более точному обучению модели в сложных сценариях, в частности при частичном закрытии лица или нестандартных углах обзора.

Для оценки эффективности предложенного подхода проведены детальные эксперименты с моделью YOLOv8 при различных значениях параметра λ_{face} . Подробные результаты обучения получены при значениях λ_{face} в диапазоне 2,0–2,7, поскольку именно эти значения обеспечили наилучшие метрики для класса «face», при этом метрики для класса «human» остались стабильными и высокими.

Для проведения экспериментов использовались следующие основные параметры обучения: модель `yolov8m`, обучение в течение 100 эпох с размером батча 16, размер изображений 640 пикселей, начальная скорость обучения 0,01.




Рисунок 3.2 — Матрица ошибок

Матрица ошибок (рис. 3.2) предоставляет обзор точности модели в отношении классов «face» и «human». Она демонстрирует, как часто модель правильно распознавала объекты каждого класса и где допускала ошибки.

На рис. 3.3 приведены примеры распознавания объектов моделью на изображениях из проверочного набора данных. Эти примеры иллюстрируют способности модели точно детектировать лица и силуэты даже в сложных условиях.

Реидентификация человека (person re-identification, re-ID) представляет собой задачу поиска и распознавания одинакового человека на разрозненных видеореамерах наблюдения. Эта проблема актуальна для систем безопасности и видеоаналитики, так как обеспечивает отслеживание перемещений человека по сети видеореамер. Классический подход к задаче re-ID состоит в извлечении признаков из изображения человека и их сравнении с эталонными образцами из заранее сформированной базы данных, после чего принимается решение о совпадении или несовпадении личности [43]. Существенными трудностями являются вариативность внешнего вида человека (в частности, различия в позе, освещении, ракурсе съемки), низкое разрешение изображений и частичные окклюзии [80; 81].

В последние годы благодаря методам глубокого обучения в решении задач идентификации и распознавания людей достигнут значительный прогресс [82; 83]. Современные нейросетевые модели обеспечивают выделение дискриминативных признаков и эффективную оптимизацию метрического пространства для

решения задачи re-ID [35]. Несмотря на это, глубокие модели требуют больших размеченных выборок для обучения и зачастую обладают низкой интерпретируемостью, работая по принципу «черного ящика». В таких условиях актуальным направлением становится исследование методов машинного обучения, обеспечивающих прозрачность и статистическую интерпретацию принимаемых решений, в частности — методов на основе байесовской классификации [46; 47].

Байесовский подход к классификации минимизирует вероятность ошибки классификации за счет использования апостериорных вероятностей классов. В контексте задачи re-ID это позволяет формулировать задачу как статистическое решение: принадлежит ли наблюдаемое изображение конкретному человеку либо при сопоставлении пар изображений — одному человеку они принадлежат [42; 45]. Ранние работы в области распознавания лиц уже демонстрировали успешное применение байесовских моделей. Так, алгоритм Bayesian Face [45] моделировал распределения различий изображений одного и разных людей как гауссовские, оптимизируя отношение апостериорных правдоподобий. Дальнейшее развитие подхода привело к созданию совместной (joint) байесовской модели, учитывающей одновременно пару изображений и повышающей точность распознавания лиц [42].

В области person re-ID байесовские идеи также активно применяются. В частности, метрические методы обучения, например KISSME [77] и XQDA [84], фактически эквивалентны байесовскому решению задачи двухклассовой классификации (внутриклассовые и межклассовые различия признаков). Регуляризованный байесовский подход обеспечивает моделирование ковариаций признаков внутри и между классами, улучшая устойчивость к шумам данных [84]. Кроме того, байесовские методы успешно используются и для уточнения результатов поиска в re-ID (re-ranking). Например, метод Bayesian Query Expansion (BQE) добавляет в запрос вероятные совпадения, рассчитанные на основе байесовской оценки правдоподобия, что значительно повышает точность на эталонных наборах данных [41].

Значительный интерес также представляет использование информационно-аналитических систем в задачах автоматического распознавания и детектирования объектов в условиях реального времени. Например, для управления транспортными и пешеходными потоками активно используются системы, основанные на нейросетевых моделях типа YOLO, обеспечивающих классификацию участников дорожного движения и корректировку работы светофоров в режиме

реального времени [85]. Другим подходом является применение методов классического компьютерного зрения — гистограмм направленных градиентов (HOG) в сочетании с классификатором на основе опорных векторов (SVM), что также обеспечивает эффективное детектирование движений людей без использования нейросетей [86]. Данные примеры демонстрируют актуальность комбинирования классических и нейросетевых подходов для решения задач распознавания и классификации объектов.

Несмотря на существующие исследования, прямое использование многоклассового байесовского классификатора для решения задачи re-ID изучено недостаточно. Цель данной работы — разработать и детально описать алгоритм многоклассовой байесовской классификации, напрямую относящий новое изображение к одному из классов личности, и экспериментально оценить его эффективность в задаче реидентификации. Исследование логически продолжает предыдущую работу автора [87], в которой была предложена архитектура глубокого кодировщика признаков для задачи re-ID. Настоящий раздел развивает этот подход, представляя полную алгоритмическую реализацию байесовского классификатора поверх признакового пространства и подтверждая эффективность данного подхода на реальных данных.

Задача реидентификации может рассматриваться как задача классификации: имеется множество Y известных личностей (классов) и новое изображение с признаковым описанием $\mathbf{x}$, необходимо определить класс y^* , которому оно принадлежит. Байесовский классификатор реализует решение:

$$y^* = \arg \max_{y \in Y} P(y | \mathbf{x}), \quad (3.2)$$

что, согласно теореме Байеса, эквивалентно максимизации $P(\mathbf{x} | y) P(y)$. Пусть для каждого класса y распределение векторных признаков $\mathbf{x}$ задано плотностью $P(\mathbf{x} | y)$, а априорная вероятность появления класса — $P(y)$. Тогда решающее правило имеет вид:

$$y^* = \arg \max_{y \in Y} [P(\mathbf{x} | y) P(y)]. \quad (3.3)$$

В предлагаемом алгоритме распределение признаков каждого класса моделируется многомерным нормальным распределением $\mathcal{N}(\boldsymbol{\mu}_y, \Sigma_y)$. Такое предположение упрощает вычисления и адекватно описывает пространство эмбедингов, извлеченных из изображений нейронной сетью. Для оценки параметров $\boldsymbol{\mu}_y, \Sigma_y$

используется обучающая выборка изображений всех классов. Оценка математического ожидания определяется как среднее арифметическое признаков класса y , а ковариационная матрица оценивается как несмещенная выборочная ковариация. Априорную вероятность класса $P(y)$ можно выбрать пропорционально количеству примеров данного класса или считать равномерной, если все классы считаются равновероятными. В проведенных экспериментах использовалась равномерная априорная вероятность.

Особым случаем является бинарная классификация пары изображений $(\mathbf{x}_1, \mathbf{x}_2)$: «тот же человек» (H_I) или «разные люди» (H_E). В этом случае байесовское решение принимается по отношению правдоподобий:

$$\frac{P(\mathbf{x}_1, \mathbf{x}_2 \mid H_I)}{P(\mathbf{x}_1, \mathbf{x}_2 \mid H_E)} \geq \tau. \quad (3.4)$$

В классическом алгоритме Bayesian Face [45] распределение разности признаков $\Delta \mathbf{x} = \mathbf{x}_1 - \mathbf{x}_2$ моделируется двумя гауссовскими распределениями с нулевыми средними и различными ковариациями. Современная совместная (joint) модель [42] рассматривает пару изображений $(\mathbf{x}_1, \mathbf{x}_2)$ целиком, что обеспечивает учет корреляции признаков напрямую. В практической реализации задачи re-ID целесообразно сначала получить эмбединги изображений с помощью нейронной сети, а затем использовать правило (3.2) для всех классов базы данных. Именно такой подход реализован в данной работе, объединяя преимущества глубоких нейросетевых признаков и байесовской классификации.

Для надежной оценки ковариаций Σ_y при малом числе изображений на один класс (что типично в задачах re-ID, где количество снимков обычно варьируется от 5 до 10 [36]) применяется регуляризация. Ковариация каждого класса аппроксимируется как смесь общей и диагональной матриц:

$$\Sigma_y = (1 - \beta) \Sigma_{\text{global}} + \beta \text{diag}(\Sigma_y), \quad (3.5)$$

где Σ_{global} — усредненная ковариация по всем классам (внутриклассовая вариация в целом по датасету); $\text{diag}(\Sigma_y)$ — диагональная матрица с дисперсиями признаков конкретного класса y . Параметр регуляризации β выбирается по критерию максимального правдоподобия на валидационной выборке. Такой подход аналогичен идее регуляризованного байесовского обучения метрик [43], где контролируется

спектр ковариационных матриц для повышения обобщающей способности модели. В экспериментах оптимальным оказалось значение $\beta \approx 0,3$, что предотвращает вырождение ковариации при малых выборках и сохраняет индивидуальные особенности классов.

Также возможно использовать метод Expectation-Maximization (EM) [43] для оценки параметров распределений. Однако в контролируемых условиях (при наличии размеченных данных) достаточно использования прямых формул оценки, дающих практически идентичные результаты.

Для извлечения векторов признаков x из изображений используются две отдельные нейронные сети-кодировщики: одна — для изображений лиц, другая — для изображений силуэтов человека. Обе модели построены на архитектуре Vision Transformer (ViT) и используют функцию потерь ArcFace [84], подтвердившую свою высокую эффективность в задачах биометрической идентификации.

Блок-схема алгоритма классификации представлена на рис. 3.4. Каждый из кодировщиков извлекает признаки следующим образом:

$$\mathbf{f} = \Phi_{\text{face}}(I_{\text{face}}), \quad \mathbf{s} = \Phi_{\text{body}}(I_{\text{body}}), \quad (3.6)$$

где $\mathbf{f}$ — эмбеddинг лица, $\mathbf{s}$ — эмбеddинг силуэта.

Архитектура Vision Transformer (ViT) [88] устроена следующим образом. Исходное изображение разбивается на непересекающиеся фрагменты (патчи) фиксированного размера, после чего каждый патч кодируется в линейное пространство и подается на вход трансформерному энкодеру, состоящему из нескольких слоев self-attention. В качестве итогового векторного представления используется специальный классификационный токен [CLS], являющийся агрегированным описанием всего изображения. Данная архитектура обеспечивает эффективное извлечение признаков как для лиц, так и для силуэтов, что подтверждает ее универсальность в контексте реидентификации.

Для обучения кодировщиков используется функция потерь ArcFace [42], повышающая дискриминативность признаков за счет введения аддитивной угловой поправки в классификационную границу. В результате применения ArcFace эмбеddинги формируют компактные и хорошо разделенные кластеры для каждого класса. В задачах реидентификации также распространена метрическая функция потерь Triplet Loss [43], направленная на минимизацию расстояния между эмбеddингами изображений одного класса и максимизацию расстояния до эмбеddингов




Рисунок 3.4 — Блок-схема алгоритма классификации

изображений других классов. Тем не менее в рамках проведенных экспериментов ArcFace показал лучшую сходимость и стабильность обучения.

Перед использованием в байесовском классификаторе признаки нормализуются по L_2 -норме:

$$\hat{\mathbf{f}} = \frac{\mathbf{f}}{\|\mathbf{f}\|_2}, \quad \hat{\mathbf{s}} = \frac{\mathbf{s}}{\|\mathbf{s}\|_2}. \quad (3.7)$$

В отличие от ряда классических подходов, центрирование признаков относительно среднего не проводится, поскольку в предложенном подходе среднее и ковариационная матрица для каждого класса оцениваются напрямую из обучающих данных.



Для объединения признаков, полученных из разных модальностей (лица и силуэта), используется байесовский подход. Итоговая логарифмическая апостериорная вероятность принадлежности наблюдения к классу вычисляется как сумма логарифмов условных плотностей для каждой из модальностей:

$$\log P(y | \hat{\mathbf{f}}, \hat{\mathbf{s}}) \propto \log P(\hat{\mathbf{f}} | y) + \log P(\hat{\mathbf{s}} | y). \quad (3.8)$$

Вклад каждой модальности считается равным, весовые коэффициенты не используются. Эксперименты подтвердили, что даже при равномерном сложении обе модальности вносят существенный вклад в точность классификации. Предварительная L_2 -нормализация обеспечивает устойчивость предлагаемого подхода вне зависимости от различий в размерности признаков пространств.

Экспериментальная оценка предложенного байесовского алгоритма классификации выполнена на открытом датасете SUNK03, содержащем изображения людей, снятых с различных камер видеонаблюдения. Для оценки эффективности метода использовался подход прямой классификации личности по изображению с вычислением точности классификации, полноты и F_1 -меры для каждого класса. В качестве признакового описания изображений использовались векторы признаков, полученные с помощью нейронных сетей-кодировщиков, обученных отдельно для изображений лиц и силуэтов.

Для иллюстрации и оценки качества полученного признакового пространства выполнены визуализации методом t -SNE отдельно для признаков лиц (рис. 3.5), силуэтов (рис. 3.6), их линейного объединения (рис. 3.7) и предложенного байесовского подхода (рис. 3.8). Визуализации показали, что использование байесовской модели интеграции признаков обеспечивает наиболее компактные и четко разделенные кластеры, соответствующие отдельным личностям.

Рисунок 3.5 — t -SNE по лицамРисунок 3.6 — t -SNE по силуэтам




Рисунок 3.7 — t -SNE по линейному объединению лиц и силуэтов




Рисунок 3.8 — t -SNE по байесовскому подходу

Визуализации признаков каждой отдельной модальности показали меньшую дискриминативность, а линейное объединение не всегда обеспечивало достаточную разделимость кластеров. Таким образом, предложенный байесовский подход эффективно агрегирует информацию от обеих модальностей, существенно улучшая дискриминативную способность пространства признаков.

Для количественного анализа рассчитаны следующие средние метрики: точность (precision) составила 95,65%, полнота (recall) — 95,54%, F_1 -мера — 94,31%, а общая точность (ассурасу) — 93,42%. Полученные показатели подтверждают высокую точность предложенного метода и его эффективность в решении задачи реидентификации.

При этом анализ результатов показал, что подавляющее большинство классов было классифицировано практически идеально (точность и полнота близки к 100%), однако для некоторых классов наблюдались ошибки, обусловленные сходством признаков между различными людьми (сходство внешнего вида одежды или частичное перекрытие на снимках).

Дополнительно построена ROC-кривая (рис. 3.9). Высокая площадь под ROC-кривой (AUC близка к 1) и удачная форма Precision-Recall-кривой подтвердили надежность классификации и хорошую разделимость классов в рамках предложенного алгоритма.

Важным аспектом является анализ сходимости предложенного алгоритма. Сходимость обеспечивается тем, что используемые признаки (эмбединги) извлекаются и нормализуются таким образом, что пространство признаков обладает гладкостью или кусочно-гладкой структурой. Байесовский алгоритм на основе многомерных нормальных распределений предполагает последовательный расчет логарифмических апостериорных вероятностей, и процедура принятия решения после вычисления этих вероятностей детерминирована и не имеет ветвлений, ведущих к неопределенным состояниям. После завершения процесса оценки параметров по обучающим данным алгоритм однозначно вычисляет итоговое решение, обеспечивая стабилизацию и гарантированную сходимость результатов.

Детерминированность предложенного алгоритма обусловлена рядом факторов. Во-первых, все исходные данные (обучающая выборка, валидационная выборка, оценки ковариаций, средние значения и априорные вероятности классов) задаются заранее и остаются неизменными в процессе вычислений. Во-вторых, вычисление признаков векторов и последующая классификация по байесовско-




Рисунок 3.9 — ROC-кривая

му правилу полностью формализованы и не содержат случайных операций (при необходимости случайной инициализации параметров нейросетей-энкодеров используется фиксированное начальное состояние с заданным случайным зерном). Это обеспечивает полную воспроизводимость результатов при повторном запуске алгоритма в идентичных условиях и исключает появление неожиданных или неопределенных значений параметров.

Массовость предложенного алгоритма достигается благодаря его универсальной структуре и отсутствию строгих ограничений на входные данные. Алгоритм не ограничен конкретным размером выборки, а вычислительные процедуры (извлечение признаков, нормализация и расчет вероятностей) применимы к наборам данных произвольного объема и структуры при условии совместимости типов данных и измеримости используемых признаков. Это обеспечивает легкое масштабирование алгоритма на более крупные и разнообразные датасеты, сохраняя общий порядок и логику вычислений.

Для объективного сравнения с современными подходами к задаче re-identification проведена оценка предложенного алгоритма на основе общепринятой метрики mean average precision (mAP). В табл. 3 представлены результаты сравнительного анализа по датасетам CUNH03, Market-1501 и MARS.

Таблица 3 — Сравнение предложенного алгоритма с state-of-the-art методами по mAP, %

Метод	CUHK03	Market-1501	MARS
Bayesian face + body (предложенный)	95,65	98,3	89,2
<i>Сравнение на CUHK03:</i>			
Proposed SGGNN	94,3	-	-
ProNet++ (ResNet50+RK)	91,9	-	-
FD-GAN	91,3	-	-
VI+LSRO	87,4	-	-
DLCE	86,4	-	-
UniHCP	83,1	-	-
Weakly Sup. Pre-train (ResNet50+BDB)	82,3	-	-
<i>Сравнение на Market-1501:</i>			
st-ReID	-	98,0	-
SSKD (GH)	-	97,36	-
CLIP-ReID+Pose2ID	-	97,3	-
SOLIDER+UFFM+AMC	-	97,0	-
Unsup. Pre-train (ResNet101+MGN)	-	97,0	-
RGT&RGPR	-	96,9	-
SOLIDER	-	96,9	-
<i>Сравнение на MARS:</i>			
B-BOT+OSM+CL Centers (Re-rank)	-	-	88,5
DenseIL	-	-	87,0
PiT	-	-	86,8
FGReID	-	-	86,2
STRF	-	-	86,1
MGH	-	-	85,8
PSTA	-	-	85,8

В результате проведенного исследования разработан и подробно описан алгоритм байесовской классификации для задачи реидентификации личности по видеоданным. Предложенный подход базируется на вероятностной модели многомерного нормального распределения признаков, извлекаемых из изображений лиц и силуэтов с использованием нейронных сетей (Vision Transformer).

Экспериментальная проверка алгоритма на наборе данных CUHK03, а также на более крупных и разнородных датасетах Market-1501 и MARS, продемонстрировала его высокую эффективность и масштабируемость. Получены средние показатели точности классификации (precision 95,65% на CUHK03, до 97,7% на Market-1501), подтверждающие надежность предложенного подхода. Анализ ROC-кривых и визуализация признакового пространства методом t -SNE показали высокую дискриминативную способность и формирование разделимых кластеров.

Также алгоритм продемонстрировал устойчивость к частичным окклюзиям и шумам, а сравнительный анализ с современными методами показал его конкурентоспособность по ключевым метрикам.

3.4 Выводы по главе

В третьей главе была представлена комплексная экспериментальная проверка разработанных методик распознавания и реидентификации человека, включающая как детекцию лиц и силуэтов, так и формирование векторных представлений (эмбеддингов) лиц. На первом этапе экспериментов осуществлялась подготовка исходных данных из набора WIDER FACE, в ходе которой исходные аннотации преобразовывались в формат, совместимый с моделью YOLOv8. Это обеспечило единообразное представление координат ограничивающих рамок для лиц и силуэтов, что критически важно для корректного обучения и последующей оценки качества детекции.

На основе модифицированной функции потерь YOLOv8 проведена серия экспериментов, направленных на уточнение параметра λ_{face} , влияющего на вес компонента потерь, связанного с ошибками распознавания лиц. Результаты, полученные при различных значениях λ_{face} , показали, что корректная настройка этого коэффициента в диапазоне 2,0–2,7 обеспечивает повышение точности детекции

лиц (Precision и mAP), при этом сохраняя высокую стабильность метрик для класса «человек» в целом. Таким образом, внедрение дополнительного слагаемого в функцию потерь, учитывающего ошибки при работе с лицами, способствовало более точному распознаванию и уменьшению ложных срабатываний, особенно в сложных сценариях с частичным закрытием лиц.

Дальнейший анализ эмбеддингов был сфокусирован на исследовании лицевых векторных представлений, формируемых моделью ViT. Набор данных СУНК03, характеризующийся большим количеством примеров и разнообразием условий съемки, использовался для обучения модели, где механизм самовнимания ViT обеспечил эффективное выделение глобальных признаков лица. Визуализация распределения эмбеддингов с помощью *t*-SNE подтвердила, что модель формирует хорошо разделенные кластеры, соответствующие различным индивидуумам, указывая на высокую дискриминационную способность. Количественные оценки, основанные на косинусном расстоянии (FAR, FRR и TAR), показали, что даже при крайне жестких ограничениях на уровень ложно принятых решений (FAR) модель сохраняет высокую точность распознавания, демонстрируя низкую частоту ложных отклонений (FRR) и высокие значения истинного принятия (TAR).

Таким образом, представленная совокупность экспериментов иллюстрирует эффективность предложенной методики в задаче распознавания и реидентификации человека. Модифицированная функция потерь YOLOv8 с учетом компонента для лиц повышает точность детекции в сценариях сложного фонового окружения и частичных перекрытий, а ViT обеспечивает формирование устойчивых и информативных эмбеддингов, обеспечивающих высокую точность различения разных лиц. Полученные результаты свидетельствуют о потенциале дальнейшей интеграции обоих подходов в систему распознавания человека, способную надежно функционировать в условиях реального времени и широкого спектра вариаций во внешнем виде и окружении.

Заключение

В ходе выполненного исследования решена научно-техническая задача, связанная с разработкой и верификацией методики распознавания и реидентификации человека, интегрирующей детектирование силуэтов и лиц с модульной системой признаков представлений и их вероятностной интеграцией. На основе обзора существующих методов и алгоритмов детекции объектов, реидентификации и комбинирования эмбедингов сформулирован ряд ограничений современных систем, в частности недостаточная точность идентификации в сложных условиях съемки, зависимость от одного типа признаков и неэффективность при высокой вариативности внешнего облика человека. Актуальность темы и поставленная цель исследования, заключающаяся в разработке методики, обеспечивающей повышение точности распознавания и реидентификации людей при рациональных вычислительных затратах, обусловили необходимость комплексного подхода, объединяющего три компонентных метода: согласованное детектирование силуэтов и лиц, формирование дискриминативных эмбедингов и их вероятностную интеграцию.

Основные результаты исследования заключаются в следующем.

1. Разработана комплексная методика реидентификации людей в информационных поисковых системах, реализующая единый конвейер обработки видеокadra и включающая четыре последовательных этапа: (1) согласованное детектирование связанных объектов «силуэт-лицо»; (2) раздельное извлечение дискриминативных эмбедингов лица и силуэта; (3) вычисление гауссовых правдоподобий для каждого класса личности; (4) принятие решения по многоклассовому MAP-критерию. Методика интегрирует три разработанных метода (положения 1–3) в единую процедуру и обеспечивает поэтапное повышение качества на каждой стадии при минимизации каскадного эффекта накопления ошибок.
2. Разработана модификация критерия обучения детектора (на базе архитектуры YOLOv8) для согласованной локализации связанных объектов «силуэт-лицо». Метод основан на введении дополнительного компонента функции потерь $\mathcal{L}_{\text{face}}$ и управляющего коэффициента λ_{face} , совместно штрафующих ошибки локализации лица в границах силу-

эта. Экспериментально показано, что значения λ_{face} в диапазоне 2,0–2,7 обеспечивают наилучшие показатели по детекции лиц без статистически значимой деградации качества детектирования класса «силуэт».

3. Предложен метод формирования дискриминативных векторных представлений (эмбеддингов) для лицевой и силуэтной модальностей на базе кодировщиков Vision Transformer (ViT), обучаемых по функции потерь ArcFace с последующей L_2 -нормировкой. Метод обеспечивает получение устойчивых описаний для каждой модальности изолированно, минимизируя межклассовые пересечения, что подтверждается визуализациями t -SNE и высокими значениями метрик качества на репрезентативных наборах данных.
4. Разработан метод интеграции лицевых и силуэтных эмбеддингов на основе байесовской модели и многоклассового MAP-критерия с автоматическим взвешиванием модальностей через ковариационные матрицы класса Σ_y в гауссовых правдоподобиях. Метод обеспечивает адаптивный вклад каждой модальности без ручной подстройки весов и корректное поведение решающего правила при временном отсутствии или зашумлении одной из модальностей. На прикладной задаче реидентификации личности (набор CUNK03) достигнуты маско-усредненные значения: Precision — 95,65 %, Recall — 95,54 %, F_1 -мера — 94,31 %, Accuracy — 93,42 %; по метрике mAP получены значения 95,65 % / 98,3 % / 89,2 % для наборов CUNK03 / Market-1501 / MARS соответственно, что превосходит базовые способы линейного объединения признаков.
5. Подтверждена практическая значимость предложенной методики. Результаты работы внедрены и используются в деятельности ФГБУ «НИЦ «Институт имени Н. Е. Жуковского»» (сокращение времени принятия решения до 5 % в системах визуального наблюдения).

Проведенные в третьей главе эксперименты показали, что модель YOLOv8 с измененной функцией потерь существенно повышает точность детекции лиц при сохранении стабильных показателей по классу «человек», особенно в сложных условиях частичного закрытия лица или неустойчивого освещения. Оптимальные значения λ_{face} в диапазоне 2,0–2,7 обеспечили увеличение mAP@0.5 на несколько процентов по сравнению с базовой реализацией, не приводя к ухудшению результатов для других объектов. Анализ ViT-эмбеддингов, сформированных для датасета CUNK03, продемонстрировал образование четких

кластеров, соответствующих конкретным индивидуумам, что свидетельствует о высокой дискриминационной способности представленных векторов. Количественные метрики, рассчитанные для эмбедингов лиц и силуэтов, указывают на низкий уровень ложных срабатываний и отказов даже при жестких порогах. Таким образом, практическая значимость подтверждается экспериментами, в которых достигнута высокая точность реидентификации при приемлемых вычислительных затратах.

Научная новизна результатов работы выражается в разработке оригинальной методики, сочетающей согласованное детектирование силуэтов и лиц с отдельным построением дискриминативных эмбедингов для каждой модальности, а также в создании нового метода вероятностной интеграции лицевых и силуэтных признаков на основе байесовской модели и многоклассового MAP-критерия с автоматическим взвешиванием модальностей через ковариационные матрицы класса. Впервые предложенная комплексная методика обеспечивает интегрированный учет лицевых и силуэтных признаков с корректным поведением решающего правила при неполноте данных, что ведет к повышению точности идентификации в режиме, близком к реальному времени, при высоком уровне вариативности исходных данных.

Перспективы развития результатов исследования заключаются в расширении набора признаков, учитываемых в формировании итогового эмбединга (в частности, атрибутов одежды, походки, характерных аксессуаров), а также в применении моделей, использующих дополнительные архитектурные новшества (гибридные решения на основе сверточных нейронных сетей и трансформеров, усовершенствованные механизмы самовнимания). Перспективным направлением является исследование смесей гауссовых распределений и непараметрических методов оценки плотностей для повышения гибкости вероятностной модели. Кроме того, целесообразно исследовать возможности распределенного обучения и более глубокого переноса (transfer learning), что востребовано при развертывании систем реидентификации в рамках гетерогенных сред и систем интеллектуального видеонаблюдения.

Таким образом, результаты диссертации свидетельствуют о том, что разработанная методика распознавания и реидентификации человека при интеграции в информационно-поисковые системы обеспечивает повышение общей точности идентификации и сокращение числа ложных тревог при сохранении высокой надежности и детальности анализа в режиме реального времени. Полученные

выводы и рекомендации имеют как теоретическое, так и прикладное значение, обеспечивая возможность эффективной разработки и адаптации систем распознавания для решения широкого круга задач в области безопасности, мониторинга и управления доступом.

В заключение автор выражает благодарность и признательность научному руководителю Гончаренко В.И. за поддержку, помощь, обсуждение результатов и научное руководство, а также сотрудникам Института информационных технологий и интеллектуальных систем Казанского федерального университета за ценные замечания и рекомендации на разных этапах подготовки диссертации.

Список сокращений и условных обозначений

$\left. \begin{matrix} a_n \\ b_n \end{matrix} \right\}$	и снова коэффициенты разложения M_i в дальнем поле соответствующие электрическим и магнитным мультиполям. Добавлено много текста, так что описание группы условных обозначений значительно превысило высоту этой группы...
$\left. \begin{matrix} a_n \\ b_n \end{matrix} \right\}$	коэффициенты разложения M_i в дальнем поле соответствующие электрическим и магнитным мультиполям
$\left. \begin{matrix} N_{e1n}^{(j)} & N_{o1n}^{(j)} \\ M_{o1n}^{(j)} & M_{e1n}^{(j)} \end{matrix} \right\}$	сферические векторные гармоники
λ	длина волны электромагнитного излучения в вакууме
μ	магнитная проницаемость в вакууме
ω	частота падающей волны
$\hat{e}$	единичный вектор
E_0	амплитуда падающего поля
j	тип функции Бесселя
k	волновой вектор падающей волны
L	общее число слоёв
l	номер слоя внутри стратифицированной сферы
n	порядок мультиполя
r, θ, φ	полярные координаты
ω	частота света, см. (1.7)
c	скорость света, стр. 33
k	модуль волнового вектора, см. (1.7), стр. 33
BEM	boundary element method, метод граничных элементов
CST MWS	Computer Simulation Technology Microwave Studio программа для компьютерного моделирования уравнений Максвелла
DDA	discrete dipole approximation, приближение дискретных диполей
FDFD	finite difference frequency domain, метод конечных разностей в частотной области

FDTD	finite difference time domain, метод конечных разностей во временной области
FEM	finite element method, метод конечных элементов
FIT	finite integration technique, метод конечных интегралов
FMM	fast multipole method, быстрый метод многополюсника
FVTD	finite volume time-domain, метод конечных объёмов во временной области
MLFMA	multilevel fast multipole algorithm, многоуровневый быстрый алгоритм многополюсника
MoM	method of moments, метод моментов
MSTM	multiple sphere T-Matrix, метод Т-матриц для множества сфер
PSTD	pseudospectral time domain method, псевдоспектральный метод во временной области
TLM	transmission line matrix method, метод матриц линий передач

Словарь терминов

TeX : Система компьютерной вёрстки, разработанная американским профессором информатики Дональдом Кнутом

панграмма : Короткий текст, использующий все или почти все буквы алфавита

Список литературы

1. *Shanmugavadivu, P.* Rapid face detection and annotation with loosely face geometry [Text] / P. Shanmugavadivu, A. Kumar // 2016 2nd International Conf. on Contemporary Computing and Informatics (IC3I). — 2016. — P. 594—597.
2. Importance of different facial parts for face detection networks [Text] / P. Hofer [et al.] // 2021 IEEE International Workshop on Biometrics and Forensics (IWBF). — 2021. — P. 1—6.
3. Adversarial Cross-Spectral Face Completion for NIR-VIS Face Recognition [Text] / R. He [et al.] // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2020. — Vol. 42, no. 5. — P. 1025—1037.
4. A near-infrared image based face recognition system [Text] / S. Z. Li [et al.] // 7th International Conf. on Automatic Face and Gesture Recognition (FGR06). — 2006. — P. 455—460.
5. Information fusion in face identification [Text] / W. Zhang [et al.] // Proc. 17th International Conf. on Pattern Recognition (ICPR 2004). Vol. 3. — 2004. — P. 950—953.
6. *Liu, C.* The development trend of evaluating face-recognition technology [Text] / C. Liu // 2014 International Conference on Mechatronics and Control (ICMC). — 2014. — P. 1540—1544.
7. *Zhao, Q.* A face detection method based on corner verifying [Text] / Q. Zhao, S. Zhang // 2011 International Conf. on Computer Science and Service System (CSSS). — 2011. — P. 2854—2857.
8. *Dang, K.* Review and comparison of face detection algorithms [Text] / K. Dang, S. Sharma // 2017 7th International Conf. on Cloud Computing, Data Science & Engineering – Confluence. — 2017. — P. 629—633.
9. *Tian, Q.* A fast face detection method for JPEG image [Text] / Q. Tian, S. Zhao // 2012 IEEE 11th International Conf. on Signal Processing. — 2012. — P. 899—902.
10. *Nehru, M.* Illumination invariant face detection using Viola Jones algorithm [Text] / M. Nehru, S. Padmavathi // 2017 4th International Conf. on Advanced Computing and Communication Systems (ICACCS). — 2017. — P. 1—4.

11. *Cutler, R.* Robust periodic motion and motion symmetry detection [Text] / R. Cutler, L. Davis // Proc. IEEE Conf. on Computer Vision and Pattern Recognition. Vol. 2. — 2000. — P. 615—622.
12. *Heisele, B.* Motion-based recognition of pedestrians [Text] / B. Heisele, C. Woehler // Proc. International Conf. on Pattern Recognition and Image Processing. — 1998. — P. 1325—1330.
13. Automatic gait recognition [Text] / M. S. Nixon [et al.] // IEE Colloq. Motion Analysis and Tracking. Vol. 3. — 1999. — P. 1—6.
14. RCAA: Relational context-aware agents for person search [Text] / X. Chang [et al.] // European Conference on Computer Vision. — 2018. — P. 84—100.
15. Hierarchical online instance matching for person search [Text] / D. Chen [et al.] // AAAI Conference on Artificial Intelligence. — 2020. — P. 10518—10525.
16. Norm-aware embedding for efficient person search [Text] / D. Chen [et al.] // Computer Vision and Pattern Recognition. — 2020. — P. 12615—12624.
17. Person search by separated modeling and a mask-guided two-stream CNN model [Text] / D. Chen [et al.] // IEEE Transactions on Image Processing. — 2020. — Vol. 29. — P. 4669—4682.
18. Instance guided proposal network for person search [Text] / W. Dong [et al.] // Computer Vision and Pattern Recognition. — 2020. — P. 2585—2594.
19. Re-ID driven localization refinement for person search [Text] / C. Han [et al.] // International Conference on Computer Vision. — 2019. — P. 9814—9823.
20. Keypoint message passing for video-based person re-identification [Text] / D. Chen [et al.] // AAAI Conference on Artificial Intelligence. — 2022.
21. *Zhong, Y.* Robust partial matching for person search in the wild [Text] / Y. Zhong, X. Wang, S. Zhang // Computer Vision and Pattern Recognition. — 2020. — P. 6827—6835.
22. *Зайцев, А. Ю.* Методы и алгоритмы реидентификации человека в видеоаналитических системах [Текст] / А. Ю. Зайцев, С. Н. Колесников, К. В. Самойлов // Известия ЮФУ. Технические науки. — 2021. — № 1. — С. 45—56.

23. *Сахаров, В. Н.* Исследование методов распознавания человека по видеоизображению [Текст] / В. Н. Сахаров, И. М. Новиков, Н. Н. Печёнкин // Вестник ЮУрГУ. Серия: Вычислительная математика и информатика. — 2020. — Т. 9, № 2. — С. 85—96.
24. *Лапшин, С. А.* Комплексный подход к задаче идентификации человека на видео [Текст] / С. А. Лапшин, В. Ю. Васильев // Системы и средства информатики. — 2019. — Т. 29, № 3. — С. 100—111.
25. *Смирнов, А. А.* Многофакторная биометрическая идентификация человека на основе анализа походки и лица [Текст] / А. А. Смирнов, И. А. Копылов, И. Г. Малышев // Журнал вычислительной математики и математической физики. — 2022. — Т. 62, № 4. — С. 678—689.
26. *Горелов, А. В.* Автоматическое распознавание и идентификация человека: обзор отечественных подходов [Текст] / А. В. Горелов, С. А. Петренко // Труды ИПУ РАН. — 2020. — № 5. — С. 27—39.
27. *Назарова, А. Д.* Тенденции развития технологий биометрии в России [Текст] / А. Д. Назарова // Столыпинский вестник. — 2023. — Т. 5, № 1. — С. 44—50.
28. *Мубинова, Э. С.* Эволюция технологий распознавания лиц и их влияние на общественное восприятие безопасности [Текст] / Э. С. Мубинова // Вестник науки. — 2024. — 9 (78). — С. 168—171.
29. *Емец, М. И.* Перспективы биометрической идентификации в контексте цифровой экономики Российской Федерации [Текст] / М. И. Емец // Креативная экономика. — 2019. — Т. 13, № 5. — С. 927—937.
30. *Bedagkar-Gala, A.* A survey of approaches and trends in person re-identification [Text] / A. Bedagkar-Gala, S. K. Shah // Image and Vision Computing. — 2014. — Vol. 32, no. 4. — P. 270—286.
31. Deep learning-based methods for person re-identification: A comprehensive review [Text] / D. Wu, S.-J. Zheng, X.-P. Zhang, [et al.] // Neurocomputing. — 2019. — Vol. 337. — P. 354—371.
32. *Zheng, L.* Person re-identification: Past, present and future [Text] / L. Zheng, Y. Yang, A. G. Hauptmann // arXiv preprint arXiv:1610.02984. — 2016.

33. *Vezzani, R.* People reidentification in surveillance and forensics: A survey [Text] / R. Vezzani, D. Baltieri, R. Cucchiara // ACM Computing Surveys. — 2013. — Vol. 46, no. 2. — P. 1—37.
34. A Comprehensive Overview of Person Re-Identification Approaches [Text] / H. Wang [et al.] // IEEE Access. — 2020.
35. *Yadav, A.* Deep learning algorithms for person re-identification: state-of-the-art and research challenges [Text] / A. Yadav, D. K. Vishwakarma // Multimedia Tools and Applications. — 2023. — Vol. 83. — P. 22005—22054.
36. Deep learning for person re-identification: A survey and outlook [Text] / M. Ye [et al.] // IEEE Trans. Pattern Anal. Mach. Intell. — 2021. — Vol. 44, no. 6. — P. 2872—2893.
37. Multi-modal Open World User Identification [Text] / B. Irfan [et al.] // ACM Trans. Human-Robot Interaction. — 2022. — Vol. 11, no. 1. — P. 1—50.
38. CNN-based multimodal human recognition in surveillance environments [Text] / J. H. Koo [et al.] // Sensors. — 2018. — Vol. 18, no. 9. — P. 3040.
39. MMM-GCN: Multi-Level Multi-Modal Graph Convolution Network for Video-Based Person Identification [Text] / Z. Liao, D. Di, J. Hao, [et al.] // LNCS. Vol. 13834. — 2023. — P. 3—15.
40. *Shoukry, N.* Multi-Modal Long-Term Person Re-Identification Using Physical Soft Bio-Metrics and Body Figure [Text] / N. Shoukry, M. A. Abd El Ghany, M. A. M. Salem // Applied Sciences. — 2022. — Vol. 12, no. 6. — P. 2835.
41. Spindle Net: Person re-identification with human body region guided feature decomposition and fusion [Text] / H. Zhao [et al.] // Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR). — 2017. — P. 907—915.
42. Bayesian face revisited: A joint formulation [Text] / D. Chen [et al.] // Proc. European Conf. on Computer Vision (ECCV). — 2012. — P. 566—579.
43. *Liong, V. E.* Regularized Bayesian metric learning for person re-identification [Text] / V. E. Liong, J. Lu, Y. Ge // Proc. ECCV Workshops, Part III, LNCS 8927. — 2014. — P. 209—224.
44. Semi-supervised Bayesian attribute learning for person re-identification [Text] / W. Liu [et al.] // Proc. AAAI Conf. on Artificial Intelligence. — 2018. — P. 680—687.

45. *Moghaddam, B.* Bayesian face recognition [Text] / B. Moghaddam, T. Jebara, A. Pentland // Pattern Recognition. — 2000. — Vol. 33, no. 11. — P. 1771—1782.
46. *Кривенко, М. П.* Байесовская классификация серий многомерных данных [Текст] / М. П. Кривенко // Системы и средства информатики. — 2020. — Т. 30, № 1. — С. 34—45.
47. *Сабуров, В. С.* Байесовский классификатор в машинном обучении [Текст] / В. С. Сабуров // Шаг в науку. — 2024. — № 1. — С. 78—81.
48. *Свидетельство о гос. регистрации программы для ЭВМ.* Программа для реидентификации личности на основе байесовского объединения эмбедингов лица и тела [Текст] / К. Д. Русаков. — Заявл. 23.03.2026, 2026617996 (Рос. Федерация).
49. *Свидетельство о гос. регистрации программы для ЭВМ.* Программа для наблюдения, захвата рабочей сцены и детектирования малоразмерных объектов в их тесном скоплении [Текст] / К. Д. Русаков, Г. К. Тевяшов. — Заявл. 04.12.2023, 2023686143 (Рос. Федерация).
50. *Русаков, К. Д.* Байесовская модель объединения признаков представлений в задаче реидентификации личности [Текст] / К. Д. Русаков // Управление большими системами. — 2025. — № 115. — С. 183—202.
51. *Русаков, К. Д.* Байесовский алгоритм классификации в задаче реидентификации личности [Текст] / К. Д. Русаков // Известия Юго-Западного государственного университета. — 2025. — Т. 29, № 3. — С. 92—108.
52. *Rusakov, K. D.* Improved Detection of Related Objects on the Example of Human Re-Identification Task [Text] / K. D. Rusakov // Proceedings of the 17th International Conference Management of Large-Scale System Development (MLSD). — Moscow : IEEE, 2024.
53. *Русаков, К. Д.* Методика решения задачи антиспуфинга по ограниченному количеству фотографий [Текст] / К. Д. Русаков, А. А. Генев, С. Ш. Хиль // Программные продукты и системы. — 2020. — Т. 33, № 1. — С. 54—60.
54. *Русаков, К. Д.* Двухэтапный подход к распознаванию коррозии металлических конструкций с использованием сверточных нейронных сетей в ходе проведения инспекций промышленных объектов [Текст] / К. Д. Русаков, А. В. Чехов // Известия Юго-Западного государственного университета. — 2021. — Т. 25, № 3. — С. 152—166.

55. *Rusakov, K. D. Automatic Modular License Plate Recognition System Using Fast Convolutional Neural Networks [Text] / K. D. Rusakov // Proceedings of the 13th International Conference Management of Large-Scale System Development (MLSD). — Moscow : IEEE, 2020. — P. 1—4.*
56. *Definition of Unique Objects by Convolutional Neural Networks Using Transfer Learning [Text] / K. D. Rusakov [et al.] // International Journal of Advanced Computer Science and Applications. — 2020. — Vol. 11, no. 11. — P. 48—54.*
57. *Rusakov, K. D. Using Convolutional Neural Networks for Estimating the Speed and Acceleration of UAVs During Takeoff and Landing Through Multicamera Detection [Text] / K. D. Rusakov // Proceedings of the 16th International Conference Management of Large-Scale System Development (MLSD). — Moscow : IEEE, 2023.*
58. *Русаков, К. Д. Использование глубокого обучения и беспилотных летательных аппаратов для мониторинга мусора в прибрежных зонах [Текст] / К. Д. Русаков // Труды 14-го Всероссийского совещания по проблемам управления (ВСПУ-2024). — Москва : ИПУ РАН, 2024. — С. 1157—1162.*
59. *Русаков, К. Д. Подход к распознаванию утопающих с помощью глубокого обучения [Текст] / К. Д. Русаков // Труды 16-й Всероссийской мультikonференции по проблемам управления (МКПУ-2023). — Волгоград : ВГТУ, 2023. — С. 257—259.*
60. *Детектирование деструктивного мультимедиа контента в социо-киберфизической системе мониторинга сети Интернет [Текст] / А. О. Исхакова [и др.] // Труды 17-й Всероссийской школы-конференции молодых ученых «Управление большими системами» (УБС-2021). — Москва - Звенигород : ИПУ РАН, 2021. — С. 202—212.*
61. *Русаков, К. Д. Алгоритмы обработки информации и управления автономным мультикоптером в задаче мониторинга протяженных объектов [Текст] / К. Д. Русаков, С. А. Диане, И. А. Россоловский // Труды 17-й Всероссийской школы-конференции молодых ученых «Управление большими системами» (УБС-2021). — Москва - Звенигород : ИПУ РАН, 2021. — С. 490—497.*

62. *Русаков, К. Д.* Модель прогноза технического состояния космического аппарата на основе искусственных модульных нейросетей [Текст] / К. Д. Русаков, В. И. Гончаренко, А. В. Горелов // Труды 19-й Международной конференции «Цифровая обработка сигналов и ее применение - DSPA-2017». Т. 2. — Москва : РНТОРЭС имени А. С. Попова, 2017. — С. 808—813.
63. *Gottumukkal, R.* An improved face recognition technique based on modular PCA approach [Text] / R. Gottumukkal, V. K. Asari // Pattern Recognition Letters. — 2004. — Vol. 25, no. 4. — P. 429—436.
64. Face recognition system using SVM classifier and feature extraction by PCA and LDA combination [Text] / J. Li [et al.] // Proc. International Conf. on Computational Intelligence and Software Engineering (CiSE). — 2009.
65. *Lu, J.* Face recognition using LDA-based algorithms [Text] / J. Lu, K. N. Plataniotis, A. N. Venetsanopoulos // IEEE Transactions on Neural Networks. — 2003. — Vol. 14, no. 1. — P. 195—200.
66. Automatic attendance monitoring system using facial recognition through feature-based methods (PCA, LDA) [Text] / S. Karthick [et al.] // Materials Today: Proceedings. — 2021.
67. Computer Vision on Identifying Persons under Real Time Surveillance using IOT [Text] / R. Saranya [et al.] // 2020 International Conf. on System, Computation, Automation and Networking (ICSCAN). — 2020. — P. 1—5.
68. *Gheissari, N.* Person reidentification using spatiotemporal appearance [Text] / N. Gheissari, T. B. Sebastian, R. Hartley // Proc. CVPR. — New York, NY, USA, 2006. — P. 1528—1535.
69. *Chahar, H.* A study on deep convolutional neural network based approaches for person re-identification [Text] / H. Chahar, N. Nain // Proc. PReMI. Vol. 10597. — Kolkata, India, 2017. — P. 543—548.
70. GhostNet: More Features from Cheap Operations [Text] / K. Han [et al.] // arXiv preprint arXiv:1911.11907. — 2019.
71. Deep Residual Learning for Image Recognition [Text] / K. He [et al.] // arXiv preprint arXiv:1512.03385. — 2015.
72. *Хачумов, М. В.* Распознавание лиц по фотографиям на основе инвариантных моментов [Текст] / М. В. Хачумов, Т. З. Нгуен // Современные проблемы науки и образования. — 2015. — № 2. — С. 10.

73. *Теленьков, А.* Система распознавания силуэтов применяется МВД в пяти регионах РФ [Текст] / А. Теленьков. — 2021. — 24.06.2021. ТАСС (ЦИПР).
74. *Li, W.* Harmonious Attention Network for Person Re-Identification [Text] / W. Li, X. Zhu, S. Gong // Proc. CVPR. — 2018. — P. 2285—2294.
75. *ArcFace: Additive Angular Margin Loss for Deep Face Recognition* [Text] / J. Deng [et al.] // Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR). — 2019. — P. 4690—4699.
76. *Соколова, А. Д.* Поиск редких данных в задаче распознавания лиц на изображениях [Текст] / А. Д. Соколова, А. В. Савченко, С. И. Николенко // Компьютерная оптика. — 2022. — Т. 46, № 2. — С. 318—327.
77. *Hermans, A.* In Defense of the Triplet Loss for Person Re-Identification [Text] / A. Hermans, L. Beyer, B. Leibe // arXiv preprint arXiv:1703.07737. — 2017.
78. *Игнатьева, С. А.* Алгоритм реидентификации людей по изображениям систем видеонаблюдения с использованием нейросетевого составного дескриптора [Текст] / С. А. Игнатьева, Р. П. Богуш // Системный анализ и прикладная информатика. — 2024. — № 1. — С. 54—65.
79. *An image is worth 16x16 words: Transformers for image recognition at scale* [Text] / A. Dosovitskiy [et al.] // arXiv preprint arXiv:2010.11929. — 2020.
80. *Ahmed, E.* An improved deep learning architecture for person re-identification [Text] / E. Ahmed, M. Jones, T. K. Marks // Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR). — 2015. — P. 3908—3916.
81. *Varior, R. R.* Gated siamese convolutional neural network architecture for human re-identification [Text] / R. R. Varior, M. Haloi, G. Wang // Proc. European Conf. on Computer Vision (ECCV). — 2016. — P. 791—808.
82. *Generalizable Person Re-identification via Balancing Alignment and Uniformity* [Text] / Y. Cho [et al.] // arXiv preprint arXiv:2411.11471. — 2024.
83. *Bag of tricks and a strong baseline for person re-identification* [Text] / H. Luo [et al.] // Proc. IEEE Conf. on Computer Vision and Pattern Recognition Workshops (CVPRW). — 2019. — P. 1487—1495.
84. *Person re-identification by local maximal occurrence representation and metric learning* [Text] / S. Liao [et al.] // Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR). — 2015. — P. 2197—2206.

85. *Бобырь, М. В.* Информационно–аналитическая система детектирования движения объектов на пешеходном переходе [Текст] / М. В. Бобырь, Н. И. Храпова // *Онтология проектирования*. — 2024. — Т. 14, 4(54). — С. 531—541.
86. *Бобырь, М. В.* О подходе к детектированию движения пешеходов методом гистограмм направленных градиентов [Текст] / М. В. Бобырь, Н. А. Милостная, Н. И. Храпова // *Электронные библиотеки*. — 2024. — Т. 27, № 4. — С. 429—447.
87. *Русаков, К. Д.* Алгоритм реидентификации личности на основе глубоких сверточных сетей [Текст] / К. Д. Русаков // *Управление большими системами: сборник трудов*. — 2025. — Т. 110.
88. BiSeNet V2: Bilateral network with guided aggregation for real-time semantic segmentation [Text] / C. Yu [et al.] // *arXiv preprint arXiv:2004.02147*. — 2020.

Список рисунков

1.1	Типовая схема системы реидентификации человека	28
2.1	Схема архитектуры YOLOv8	38
2.2	Блок-схема предлагаемого алгоритма байесовской реидентификации .	48
2.3	Архитектура Vision Transformer	50
3.1	Графики зависимостей показателей качества от λ_{face}	67
3.2	Матрица ошибок	68
3.3	Примеры работы модели	69
3.4	Блок-схема алгоритма классификации	74
3.5	t -SNE по лицам	76
3.6	t -SNE по силуэтам	76
3.7	t -SNE по линейному объединению лиц и силуэтов	77
3.8	t -SNE по байесовскому подходу	77
3.9	ROC-кривая	79

Список таблиц

1	Характеристики сервера	60
2	Сравнительная таблица результатов обучения модели при различном λ_{face}	67
3	Сравнение предложенного алгоритма с state-of-the-art методами по mAP, %	80
4	Наименование таблицы средней длины	108
5	Тестовые функции для оптимизации, D — размерность. Для всех функций значение в точке глобального минимума равно нулю.	113
6	Длинная таблица с примером чересстрочного форматирования	116
7	Стандартные префиксы ссылок	118

Приложение А

Примеры вставки листингов программного кода

Для крупных листингов есть два способа. Первый красивый, но в нём могут быть проблемы с поддержкой кириллицы (у вас может встречаться в комментариях и печатаемых сообщениях), он представлен на листинге [A.1](#). Второй не такой

Листинг A.1 Программа „Hello, world“ на C++

```

#include <iostream>
using namespace std;

int main() //кириллица в комментариях при xelatex и lua latex имеет
           проблемы с пробелами
5  {
    cout << "Hello, world" << endl; //latin letters in commentaries
    system("pause");
    return 0;
10 }

```

красивый, но без ограничений (см. листинг [A.2](#)).

Листинг A.2 Программа „Hello, world“ без подсветки

```

#include <iostream>
using namespace std;

int main() //кириллица в комментариях
{
    cout << "Привет, мир" << endl;
}

```

Можно использовать первый для вставки небольших фрагментов внутри текста, а второй для вставки полного кода в приложении, если таковое имеется.

Если нужно вставить совсем короткий пример кода (одна или две строки), то выделение линейками и нумерация может смотреться чересчур громоздко. В таких случаях можно использовать окружения `lstlisting` или `Verb` без

ListingEnv. Приведём такой пример с указанием языка программирования, отличного от заданного по умолчанию:

```
| fibs = 0 : 1 : zipWith (+) fibs (tail fibs)
```

Такое решение — со вставкой нумерованных листингов покрупнее и вставок без выделения для маленьких фрагментов — выбрано, например, в книге Эндрю Таненбаума и Тодда Остина по архитектуре компьютера.

Наконец, для оформления идентификаторов внутри строк (функция `main` и тому подобное) используется `lstinline` или, самое простое, моноширинный текст (`\texttt`).

Пример A.3, иллюстрирующий подключение переопределённого языка. Может быть полезным, если подсветка кода работает криво. Без дополнительного окружения, с подписью и ссылкой, реализованной встроенным средством.

Листинг A.3 Пример листинга с подписью собственными средствами

```
## Caching the Inverse of a Matrix

## Matrix inversion is usually a costly computation and there may be some
## benefit to caching the inverse of a matrix rather than compute it
## repeatedly
5 ## This is a pair of functions that cache the inverse of a matrix.

## makeCacheMatrix creates a special "matrix" object that can cache its
## inverse

makeCacheMatrix <- function(x = matrix()) {#кириллица в комментариях при
  xelatex и lualatex имеет проблемы с пробелами
10   i <- NULL
   set <- function(y) {
     x <- y
     i <- NULL
   }
15   get <- function() x
   setSolved <- function(solve) i <- solve
   getSolved <- function() i
   list(set = set, get = get,
20     setSolved = setSolved,
     getSolved = getSolved)

}
```

```

25 ## cacheSolve computes the inverse of the special "matrix" returned by
## makeCacheMatrix above. If the inverse has already been calculated (and
the
## matrix has not changed), then the cachesolve should retrieve the inverse
from
## the cache.

30 cacheSolve <- function(x, ...) {
    ## Return a matrix that is the inverse of 'x'
    i <- x$getSolved()
    if(!is.null(i)) {
        message("getting cached data")
35     return(i)
    }
    data <- x$get()
    i <- solve(data, ...)
    x$setSolved(i)
40     i
}

```

Листинг A.4 подгружается из внешнего файла. Приходится загружать без окружения дополнительного. Иначе по страницам не переносится.

Листинг A.4 Листинг из внешнего файла

```

# Analysis of data on Course Project at Getting and Cleaning data course of
Data Science track at Coursera.

# Part 1. Merges the training and the test sets to create one data set.
# 3. Uses descriptive activity names to name the activities in the data set
5 # 4. Appropriately labels the data set with descriptive variable names.

if (!file.exists("UCI HAR Dataset")) {
    stop("You need 'UCI HAR Dataset' folder full of data")
}

10

library(plyr) # for mapvalues

15 #getting common data
features <- read.csv("UCI HAR Dataset/features.txt", sep=" ", header = FALSE,
                    colClasses = c("numeric", "character"))
activity_labels <- read.csv("UCI HAR Dataset/activity_labels.txt", sep="",

```

```

                                header = FALSE,colClasses = c("numeric", "
                                character"))
20
#getting train set data
subject_train <- read.csv("UCI HAR Dataset/train/subject_train.txt",
                                header = FALSE,colClasses = "numeric",col.names="
                                Subject")
y_train <- read.csv("UCI HAR Dataset/train/y_train.txt", header = FALSE,
25                                colClasses = "numeric")
x_train <- read.csv("UCI HAR Dataset/train/X_train.txt",sep="", header =
                                FALSE,
                                colClasses = "numeric",col.names=features$V2,check.names
                                = FALSE)

activity_train <- as.data.frame(mapvalues(y_train$V1, from = activity_labels
                                $V1,
30                                to = activity_labels$V2))
names(activity_train) <- "Activity"

#getting test set data
35 subject_test <- read.csv("UCI HAR Dataset/test/subject_test.txt",
                                header = FALSE,colClasses = "numeric",col.names="
                                Subject")
y_test <- read.csv("UCI HAR Dataset/test/y_test.txt", header = FALSE,
                                colClasses = "numeric")
40 x_test <- read.csv("UCI HAR Dataset/test/X_test.txt",sep="", header = FALSE,
                                colClasses = "numeric",col.names=features$V2,check.names
                                = FALSE)

activity_test <- as.data.frame(mapvalues(y_test$V1, from = activity_labels$
                                V1,
                                to = activity_labels$V2))
45 names(activity_test) <- "Activity"

# Forming full dataframe
data_train <- cbind(x_train,subject_train,activity_train)
50 data_test <- cbind(x_test,subject_test,activity_test)
data <- rbind(data_train, data_test)

# Cleaning memory

```

```

rm(features, activity_labels, subject_train, y_train, x_train, activity_
train,
55 subject_test, y_test, x_test, activity_test, data_train, data_test)

# Part 2. Extracts only the measurements on the mean and standard deviation
for each measurement.

60 cols2match <- grep("(mean|std)", names(data))

# Excluded gravityMean, tBodyAccMean, tBodyAccJerkMean, tBodyGyroMean,
# tBodyGyroJerkMean, as these represent derivations of angle data, as
# opposed to the original feature vector.
65

# Subsetting data frame, also moving last columns to be first
Subsetted_data_frame <- data[, c(562, 563, cols2match)]

# Part 5. From the data set in step 4, creates a second, independent tidy
data set
70 # with the average of each variable for each activity and each subject.

library(dplyr) # for %>% and summarise_each

75 tidydata <- Subsetted_data_frame %>% group_by(Subject, Activity) %>%
summarise_each(funs(mean))

write.table(tidydata, "tidydata.txt", row.names=FALSE)

```

Приложение Б

Очень длинное название второго приложения, в котором продемонстрирована работа с длинными таблицами

Б.1 Подраздел приложения

Вот размещается длинная таблица:

Параметр	Умолч.	Тип	Описание
&INP			
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$)

продолжение следует

(продолжение)			
Параметр	Умолч.	Тип	Описание
mars kick	0	int	1: генерация белого шума
	1	int	2: генерация белого шума симметрично относительно экватора
mars kick	0	int	1: инициализация модели для планеты Марс
	1	int	0: инициализация без шума ($p_s = const$)
mars kick	0	int	1: генерация белого шума
	1	int	2: генерация белого шума симметрично относительно экватора
mars kick	0	int	1: инициализация модели для планеты Марс
	1	int	0: инициализация без шума ($p_s = const$)
mars kick	0	int	1: генерация белого шума
	1	int	2: генерация белого шума симметрично относительно экватора
mars kick	0	int	1: инициализация модели для планеты Марс
	1	int	0: инициализация без шума ($p_s = const$)
mars kick	0	int	1: генерация белого шума
	1	int	2: генерация белого шума симметрично относительно экватора
mars kick	0	int	1: инициализация модели для планеты Марс
	1	int	0: инициализация без шума ($p_s = const$)
mars kick	0	int	1: генерация белого шума
	1	int	2: генерация белого шума симметрично относительно экватора
&SURFPAR			
kick	1	int	0: инициализация без шума ($p_s = const$)
	1	int	1: генерация белого шума
mars kick	0	int	2: генерация белого шума симметрично относительно экватора
	1	int	1: инициализация модели для планеты Марс
mars kick	0	int	0: инициализация без шума ($p_s = const$)
	1	int	1: генерация белого шума
mars kick	0	int	2: генерация белого шума симметрично относительно экватора
	1	int	1: инициализация модели для планеты Марс
mars kick	0	int	0: инициализация без шума ($p_s = const$)
	1	int	1: генерация белого шума
mars kick	0	int	2: генерация белого шума симметрично относительно экватора
	1	int	1: инициализация модели для планеты Марс
mars kick	0	int	0: инициализация без шума ($p_s = const$)
	1	int	1: генерация белого шума
mars kick	0	int	2: генерация белого шума симметрично относительно экватора
	1	int	1: инициализация модели для планеты Марс
продолжение следует			

(продолжение)			
Параметр	Умолч.	Тип	Описание
mars	0	int	экватора
kick	1	int	1: инициализация модели для планеты Марс 0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс

Б.2 Ещё один подраздел приложения

Нужно больше подразделов приложения! Конвынёры витюпырата но нам, тебиквьюэ мэнтётюм позтюлант ед про. Дуо за лаудым копиюжаы, нык мовэт вэни-ам льебэравичсы эю, нам эпикюре дэтракто рыкючабо ыт.

Пример длинной таблицы с записью продолжения по ГОСТ 2.105:

Таблица 4 — Наименование таблицы средней длины

Параметр	Умолч.	Тип	Описание
&INP			
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс

Продолжение таблицы 4

Параметр	Умолч.	Тип	Описание
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс

Продолжение таблицы 4

Параметр	Умолч.	Тип	Описание
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
&SURFPAR			
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора

Продолжение таблицы 4

Параметр	Умолч.	Тип	Описание
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс
kick	1	int	0: инициализация без шума ($p_s = const$) 1: генерация белого шума 2: генерация белого шума симметрично относительно экватора
mars	0	int	1: инициализация модели для планеты Марс

Б.3 Использование длинных таблиц с окружением *longtblr* из пакета *tabularray*

В таблице 5 более книжный вариант длинной таблицы, используя окружение *longtblr* из пакета *tabularray* и разнообразные разделители (*toprule*, *midrule*, *bottomrule*) из пакета *booktabs*.

Чтобы визуально таблица смотрелась лучше, можно использовать следующие параметры. Таблица задаётся на всю ширину, *longtblr* позволяет делить ширину колонок пропорционально — тут три колонки в пропорции 1.1:1.1:4 — для каждой колонки первый параметр в описании $X[]$. Кроме того, в таблице убраны отступы слева и справа с помощью $@\{}$ в преамбуле таблицы. К первому и второму столбцу применяется модификатор

$\gt\{\backslash setlength\{\backslash baselineskip\}\{0.7\backslash baselineskip\}\}$,

который уменьшает межстрочный интервал для текста таблиц (иначе заголовок второго столбца значительно шире, а двухстрочное имя сливается с окружающими). Для первой и второй колонки текст в ячейках выравнивается по центру как по вертикали, так и по горизонтали — задаётся буквами *m* и *s* в описании столбца $X[]$.

Так как формулы большие — используется окружение *alignedat*, чтобы отступ был одинаковый у всех формул — он сделан для всех, хотя для большей части можно было и не использовать. Чтобы формулы занимали поменьше места в каждом столбце формулы (где надо) используется $\backslash textstyle$ — он делает дроби меньше, у знаков суммы и произведения — индексы сбоку. Иногда формула слишком большая, сливается со следующей, поэтому после неё ставится небольшой дополнительный отступ $\backslash vspace*{2ex}$. Для штрафных функций — размер фигурных скобок задан вручную $\backslash Big\{$, т. к. не умеет *alignedat* работать с $\backslash left$ и $\backslash right$ через несколько строк/колонок.

В примечании к таблице наоборот, окружение *cases* даёт слишком большие промежутки между вариантами, чтобы их уменьшить, в конце каждой строчки окружения использовался отрицательный дополнительный отступ $\backslash\backslash[-0.5em]$.

Таблица 5 — Тестовые функции для оптимизации, D — размерность. Для всех функций значение в точке глобального минимума равно нулю.

Имя	Стартовый диапазон параметров	Функция
сфера	$[-100, 100]^D$	$f_1(x) = \sum_{i=1}^D x_i^2$
Schwefel 2.22	$[-10, 10]^D$	$f_2(x) = \sum_{i=1}^D x_i + \prod_{i=1}^D x_i $
Schwefel 1.2	$[-100, 100]^D$	$f_3(x) = \sum_{i=1}^D \left(\sum_{j=1}^i x_j \right)^2$
Schwefel 2.21	$[-100, 100]^D$	$f_4(x) = \max_i \{ x_i \}$
Rosenbrock	$[-30, 30]^D$	$f_5(x) = \sum_{i=1}^{D-1} \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right]$
ступенчатая	$[-100, 100]^D$	$f_6(x) = \sum_{i=1}^D \lfloor x_i + 0.5 \rfloor^2$
зашумлённая квартическая	$[-1.28, 1.28]^D$	$f_7(x) = \sum_{i=1}^D ix_i^4 + rand[0,1)$
Schwefel 2.26	$[-500, 500]^D$	$f_8(x) = \sum_{i=1}^D -x_i \sin \sqrt{ x_i } +$ $+ D \cdot 418.98288727243369$
Rastrigin	$[-5.12, 5.12]^D$	$f_9(x) = \sum_{i=1}^D [x_i^2 - 10 \cos(2\pi x_i) + 10]$
Ackley	$[-32, 32]^D$	$f_{10}(x) = -20 \exp\left(-0.2\sqrt{\frac{1}{D} \sum_{i=1}^D x_i^2}\right) -$ $-\exp\left(\frac{1}{D} \sum_{i=1}^D \cos(2\pi x_i)\right) + 20 + e$
Griewank	$[-600, 600]^D$	$f_{11}(x) = \frac{1}{4000} \sum_{i=1}^D x_i^2 - \prod_{i=1}^D \cos(x_i/\sqrt{i}) + 1$
штрафная 1	$[-50, 50]^D$	$f_{12}(x) = \frac{\pi}{D} \left\{ 10 \sin^2(\pi y_1) + \right.$ $\left. + \sum_{i=1}^{D-1} (y_i - 1)^2 [1 + 10 \sin^2(\pi y_{i+1})] + \right.$ $\left. + (y_D - 1)^2 \right\} + \sum_{i=1}^D u(x_i, 10, 100, 4)$

продолжение следует

(продолжение)

Имя	Стартовый диапазон параметров	Функция
штрафная 2	$[-50, 50]^D$	$f_{13}(x) = 0.1 \left\{ \sin^2(3\pi x_1) + \right.$ $+ \sum_{i=1}^{D-1} (x_i - 1)^2 [1 + \sin^2(3\pi x_{i+1})] +$ $+ (x_D - 1)^2 [1 + \sin^2(2\pi x_D)] \left. \right\} +$ $+ \sum_{i=1}^D u(x_i, 5, 100, 4)$
сфера	$[-100, 100]^D$	$f_1(x) = \sum_{i=1}^D x_i^2$
Schwefel 2.22	$[-10, 10]^D$	$f_2(x) = \sum_{i=1}^D x_i + \prod_{i=1}^D x_i $
Schwefel 1.2	$[-100, 100]^D$	$f_3(x) = \sum_{i=1}^D \left(\sum_{j=1}^i x_j \right)^2$
Schwefel 2.21	$[-100, 100]^D$	$f_4(x) = \max_i \{ x_i \}$
Rosenbrock	$[-30, 30]^D$	$f_5(x) = \sum_{i=1}^{D-1} \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right]$
ступенчатая	$[-100, 100]^D$	$f_6(x) = \sum_{i=1}^D \lfloor x_i + 0.5 \rfloor^2$
зашумлённая квартическая	$[-1.28, 1.28]^D$	$f_7(x) = \sum_{i=1}^D i x_i^4 + rand[0, 1)$
Schwefel 2.26	$[-500, 500]^D$	$f_8(x) = \sum_{i=1}^D -x_i \sin \sqrt{ x_i } +$ $+ D \cdot 418.98288727243369$
Rastrigin	$[-5.12, 5.12]^D$	$f_9(x) = \sum_{i=1}^D [x_i^2 - 10 \cos(2\pi x_i) + 10]$
Ackley	$[-32, 32]^D$	$f_{10}(x) = -20 \exp \left(-0.2 \sqrt{\frac{1}{D} \sum_{i=1}^D x_i^2} \right) -$ $- \exp \left(\frac{1}{D} \sum_{i=1}^D \cos(2\pi x_i) \right) + 20 + e$
Griewank	$[-600, 600]^D$	$f_{11}(x) = \frac{1}{4000} \sum_{i=1}^D x_i^2 - \prod_{i=1}^D \cos(x_i / \sqrt{i}) + 1$

продолжение следует

(окончание)

Имя	Стартовый диапазон параметров	Функция
штрафная 1	$[-50, 50]^D$	$f_{12}(x) = \frac{\pi}{D} \left\{ 10 \sin^2(\pi y_1) + \right.$ $\left. + \sum_{i=1}^{D-1} (y_i - 1)^2 [1 + 10 \sin^2(\pi y_{i+1})] + \right.$ $\left. + (y_D - 1)^2 \right\} + \sum_{i=1}^D u(x_i, 10, 100, 4)$
штрафная 2	$[-50, 50]^D$	$f_{13}(x) = 0.1 \left\{ \sin^2(3\pi x_1) + \right.$ $\left. + \sum_{i=1}^{D-1} (x_i - 1)^2 [1 + \sin^2(3\pi x_{i+1})] + \right.$ $\left. + (x_D - 1)^2 [1 + \sin^2(2\pi x_D)] \right\} +$ $+ \sum_{i=1}^D u(x_i, 5, 100, 4)$
Примечание — Для функций f_{12} и f_{13} используется $y_i = 1 + \frac{1}{4}(x_i + 1)$ и $u(x_i, a, k, m) = \begin{cases} k(x_i - a)^m, & x_i > a \\ 0, & -a \leq x_i \leq a \\ k(-x_i - a)^m, & x_i < -a \end{cases}$		

Б.4 Форматирование внутри таблиц

В таблице 6 пример с чересстрочным форматированием. Это реализовано средствами, доступными в таблицах пакета `tabularray`.

В таблице 6 каждая чётная строчка (заголовок таблицы тоже считается за строчку) — синяя, нечётная — с наклоном и слегка поднята вверх. Визуально это приводит к тому, что среднее значение и среднеквадратичное изменение группируются и хорошо выделяются взглядом в таблице. Сохраняется возможность отдельные значения в таблице выделить цветом или шрифтом. К первому и второму столбцу форматирование не применяется по сути таблицы, к шестому общее форматирование не применяется для наглядности.

Таблица 6 — Длинная таблица с примером чересстрочного форматирования

	Итера- ции	<i>JADE++</i>	<i>JADE</i>	<i>jDE</i>	SaDE	<i>DE/rand</i> /1/bin	<i>PSO</i>
f1	1500	1.8E-60 (8.4E-60)	1.3E-54 (9.2E-54)	2.5E-28 (3.5E-28)	4.5E-20 (6.9E-20)	9.8E-14 (8.4E-14)	9.6E-42 (2.7E-41)
f2	2000	1.8E-25 (8.8E-25)	3.9E-22 (2.7E-21)	1.5E-23 (1.0E-23)	1.9E-14 (1.1E-14)	1.6E-09 (1.1E-09)	9.3E-21 (6.3E-20)
f3	5000	5.7E-61 (2.7E-60)	6.0E-87 (1.9E-86)	5.2E-14 (1.1E-13)	9.0E-37 (5.4E-36)	6.6E-11 (8.8E-11)	2.5E-19 (3.9E-19)
f4	5000	8.2E-24 (4.0E-23)	4.3E-66 (1.2E-65)	1.4E-15 (1.0E-15)	7.4E-11 (1.8E-10)	4.2E-01 (1.1E+00)	4.4E-14 (9.3E-14)
f5	3000	8.0E-02 (5.6E-01)	3.2E-01 (1.1E+00)	1.3E+01 (1.4E+01)	2.1E+01 (7.8E+00)	2.1E+00 (1.5E+00)	2.5E+01 (3.2E+01)
f6	100	2.9E+00 (1.2E+00)	5.6E+00 (1.6E+00)	1.0E+03 (2.2E+02)	9.3E+02 (1.8E+02)	4.7E+03 (1.1E+03)	4.5E+01 (2.4E+01)
f7	3000	6.4E-04 (2.5E-04)	6.8E-04 (2.5E-04)	3.3E-03 (8.5E-04)	4.8E-03 (1.2E-03)	4.7E-03 (1.2E-03)	2.5E-03 (1.4E-03)
f8	1000	3.3E-05 (2.3E-05)	7.1E+00 (2.8E+01)	7.9E-11 (1.3E-10)	4.7E+00 (3.3E+01)	5.9E+03 (1.1E+03)	2.4E+03 (6.7E+02)
f9	1000	1.0E-04 (6.0E-05)	1.4E-04 (6.5E-05)	1.5E-04 (2.0E-04)	1.2E-03 (6.5E-04)	1.8E+02 (1.3E+01)	5.2E+01 (1.6E+01)
f10	500	8.2E-10 (6.9E-10)	3.0E-09 (2.2E-09)	3.5E-04 (1.0E-04)	2.7E-03 (5.1E-04)	1.1E-01 (3.9E-02)	4.6E-01 (6.6E-01)
f11	500	9.9E-08 (6.0E-07)	2.0E-04 (1.4E-03)	1.9E-05 (5.8E-05)	7.8E-04 (1.2E-03)	2.0E-01 (1.1E-01)	1.3E-02 (1.7E-02)
f12	500	4.6E-17 (1.9E-16)	3.8E-16 (8.3E-16)	1.6E-07 (1.5E-07)	1.9E-05 (9.2E-06)	1.2E-02 (1.0E-02)	1.9E-01 (3.9E-01)
f13	500	2.0E-16 (6.5E-16)	1.2E-15 (2.8E-15)	1.5E-06 (9.8E-07)	6.1E-05 (2.0E-05)	7.5E-02 (3.8E-02)	2.9E-03 (4.8E-03)
f1	1500	1.8E-60 (8.4E-60)	1.3E-54 (9.2E-54)	2.5E-28 (3.5E-28)	4.5E-20 (6.9E-20)	9.8E-14 (8.4E-14)	9.6E-42 (2.7E-41)
f2	2000	1.8E-25 (8.8E-25)	3.9E-22 (2.7E-21)	1.5E-23 (1.0E-23)	1.9E-14 (1.1E-14)	1.6E-09 (1.1E-09)	9.3E-21 (6.3E-20)

продолжение следует

(окончание)

Итера- ции		<i>JADE++</i>	<i>JADE</i>	<i>jDE</i>	SaDE	<i>DE/rand</i> /1/bin	<i>PSO</i>
f3	5000	5.7E-61 (2.7E-60)	6.0E-87 (1.9E-86)	5.2E-14 (1.1E-13)	9.0E-37 (5.4E-36)	6.6E-11 (8.8E-11)	2.5E-19 (3.9E-19)
f4	5000	8.2E-24 (4.0E-23)	4.3E-66 (1.2E-65)	1.4E-15 (1.0E-15)	7.4E-11 (1.8E-10)	4.2E-01 (1.1E+00)	4.4E-14 (9.3E-14)
f5	3000	8.0E-02 (5.6E-01)	3.2E-01 (1.1E+00)	1.3E+01 (1.4E+01)	2.1E+01 (7.8E+00)	2.1E+00 (1.5E+00)	2.5E+01 (3.2E+01)
f6	100	2.9E+00 (1.2E+00)	5.6E+00 (1.6E+00)	1.0E+03 (2.2E+02)	9.3E+02 (1.8E+02)	4.7E+03 (1.1E+03)	4.5E+01 (2.4E+01)
f7	3000	6.4E-04 (2.5E-04)	6.8E-04 (2.5E-04)	3.3E-03 (8.5E-04)	4.8E-03 (1.2E-03)	4.7E-03 (1.2E-03)	2.5E-03 (1.4E-03)
f8	1000	3.3E-05 (2.3E-05)	7.1E+00 (2.8E+01)	7.9E-11 (1.3E-10)	4.7E+00 (3.3E+01)	5.9E+03 (1.1E+03)	2.4E+03 (6.7E+02)
f9	1000	1.0E-04 (6.0E-05)	1.4E-04 (6.5E-05)	1.5E-04 (2.0E-04)	1.2E-03 (6.5E-04)	1.8E+02 (1.3E+01)	5.2E+01 (1.6E+01)
f10	500	8.2E-10 (6.9E-10)	3.0E-09 (2.2E-09)	3.5E-04 (1.0E-04)	2.7E-03 (5.1E-04)	1.1E-01 (3.9E-02)	4.6E-01 (6.6E-01)
f11	500	9.9E-08 (6.0E-07)	2.0E-04 (1.4E-03)	1.9E-05 (5.8E-05)	7.8E-04 (1.2E-03)	2.0E-01 (1.1E-01)	1.3E-02 (1.7E-02)
f12	500	4.6E-17 (1.9E-16)	3.8E-16 (8.3E-16)	1.6E-07 (1.5E-07)	1.9E-05 (9.2E-06)	1.2E-02 (1.0E-02)	1.9E-01 (3.9E-01)
f13	500	2.0E-16 (6.5E-16)	1.2E-15 (2.8E-15)	1.5E-06 (9.8E-07)	6.1E-05 (2.0E-05)	7.5E-02 (3.8E-02)	2.9E-03 (4.8E-03)

Б.5 Стандартные префиксы ссылок

Общепринятым является следующий формат ссылок: <prefix>:<label>. Например, \label{fig:knuth}; \ref{tab:test1}; label={lst:external1}. В таблице 7 приведены стандартные префиксы для различных типов ссылок.

Таблица 7 — Стандартные префиксы ссылок

Префикс	Описание
ch:	Глава
sec:	Секция
subsec:	Подсекция
fig:	Рисунок
tab:	Таблица
eq:	Уравнение
lst:	Листинг программы
itm:	Элемент списка
alg:	Алгоритм
app:	Секция приложения

Для упорядочивания ссылок можно использовать разделительные символы. Например, `\label{fig:scheemes/my_scheeme}` или `\label{lst:dts/linked_list}`.

Б.6 Очередной подраздел приложения

Нужно больше подразделов приложения!

Б.7 И ещё один подраздел приложения

Нужно больше подразделов приложения!

Перв. примен.		Приложение В			
Справ. №					
Подп. и дата		Инв. № дубл.		Инв. № подл	
Взам. инв. №		Инв. инв. №		Инв. инв. №	
Подп. и дата		Подп. и дата		Подп. и дата	
Изм.		Лист		№ докум.	
Разраб.		Автор		Подп.	
Пров.				Дата	
Т.Контр.					
Н.Контр.					
Утв.					
Вакуум				Сферический куб	
Лит.				Масса	
Лист 1				Листов 1	
Масштаб				0 з.	
РАН				2:1	

30.00 mm

30.00 mm

28.07 °

20.00 mm

4.00 mm

10.00 mm

13.00 mm

10.00 mm

R2.00 mm

A1 (3:1)

В - В